

SICO70

SISTEMAS INTELIGENTES 2

Aula 01 - Introdução às Redes
Neurais Artificiais

Prof. Rafael G. Mantovani



Apucarana - PR, Brasil

Universidade Tecnológica Federal do Paraná (UTFPR)
Engenharia de Computação

Roteiro

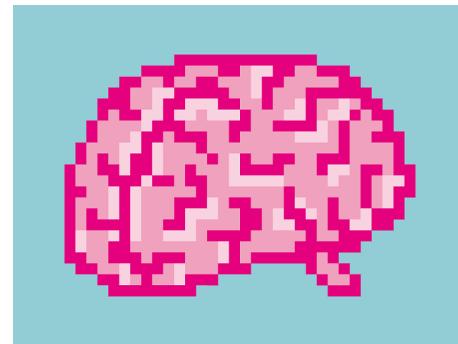
- 1 Introdução**
- 2 Redes Neurais Artificiais**
- 3 Neurônio Artificial**
- 4 Modelagem de Redes Neurais**
- 5 Síntese / Próximas Aulas**
- 6 Referências**

Roteiro

- 1 Introdução**
- 2 Redes Neurais Artificiais**
- 3 Neurônio Artificial**
- 4 Modelagem de Redes Neurais**
- 5 Síntese / Próximas Aulas**
- 6 Referências**

Introdução

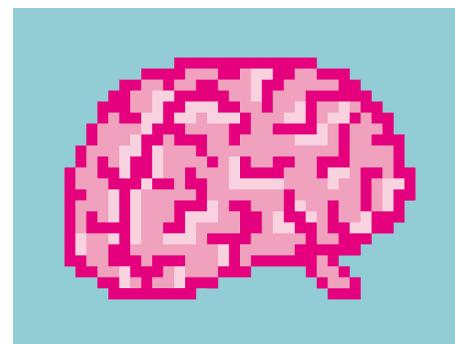
Introdução



cérebro

Introdução

Processamento
não-linear



Paralelismo

Reconhecimento
Padrões

Percepção/
Movimentos

cérebro

Adaptabilidade

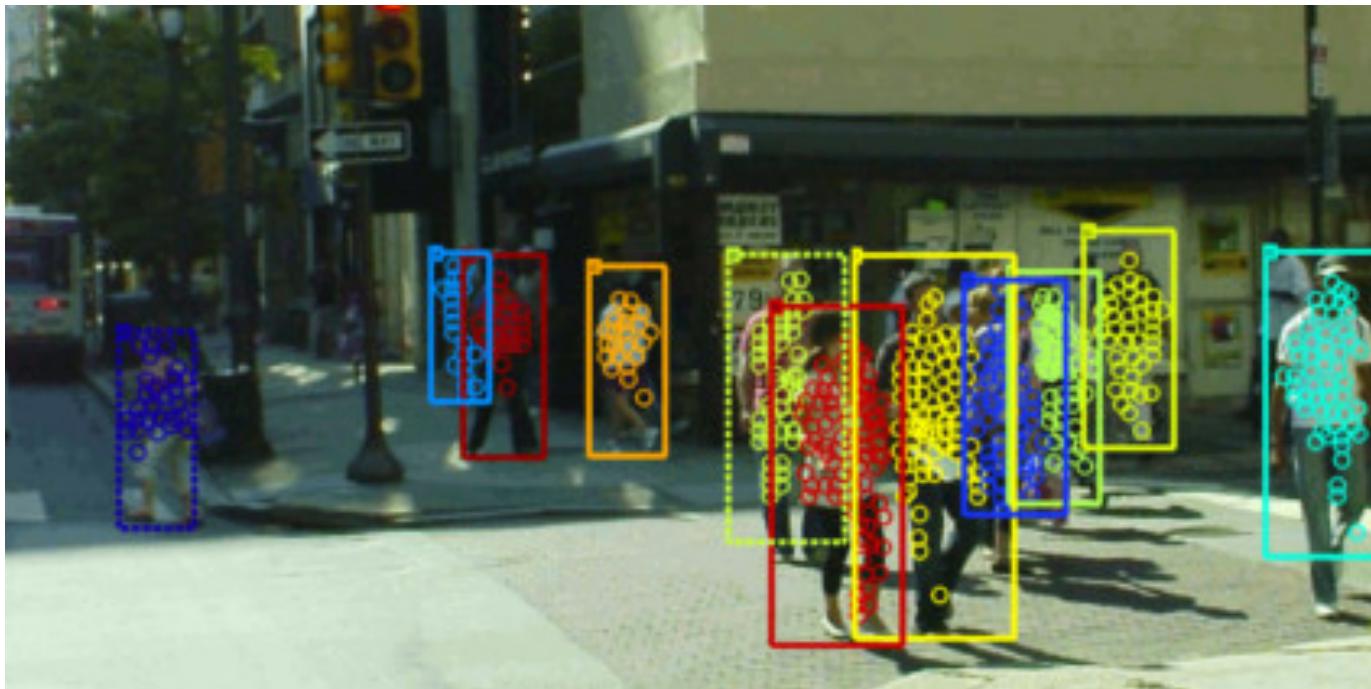
Tarefas
Complexas

Introdução

Muito interessante, mas quais **tipos de tarefas** o cérebro nos ajuda a realizar?

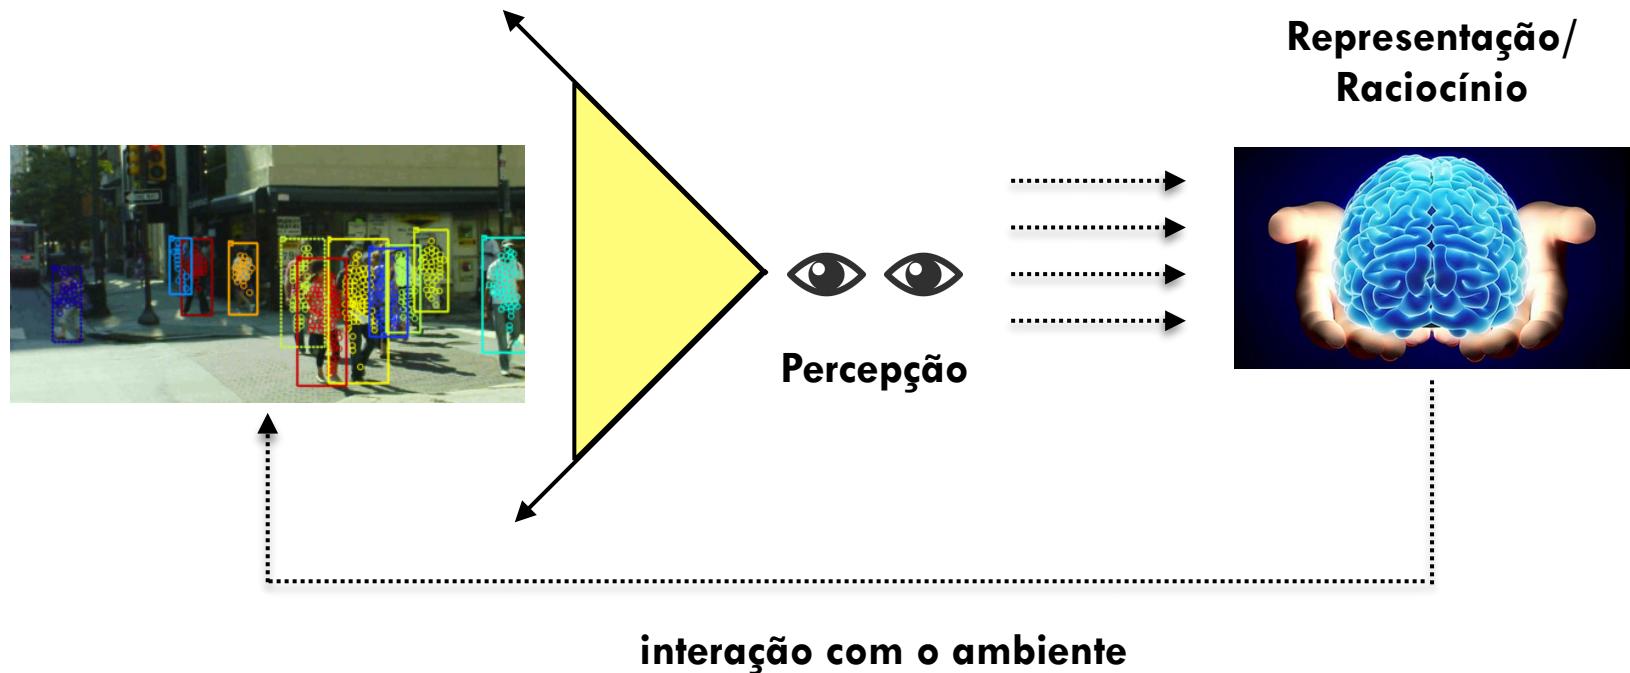
Introdução

- Visão humana



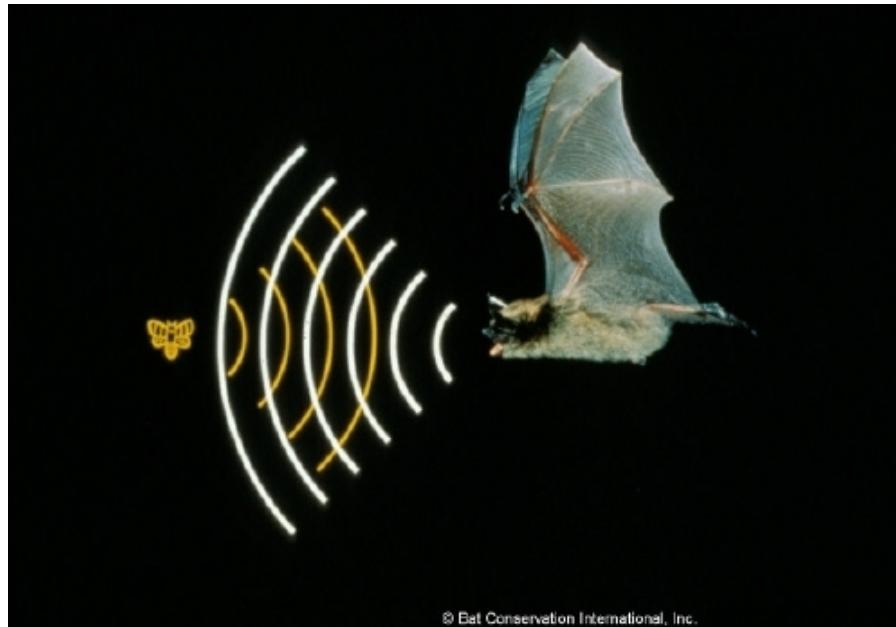
Introdução

- Visão humana



Introdução

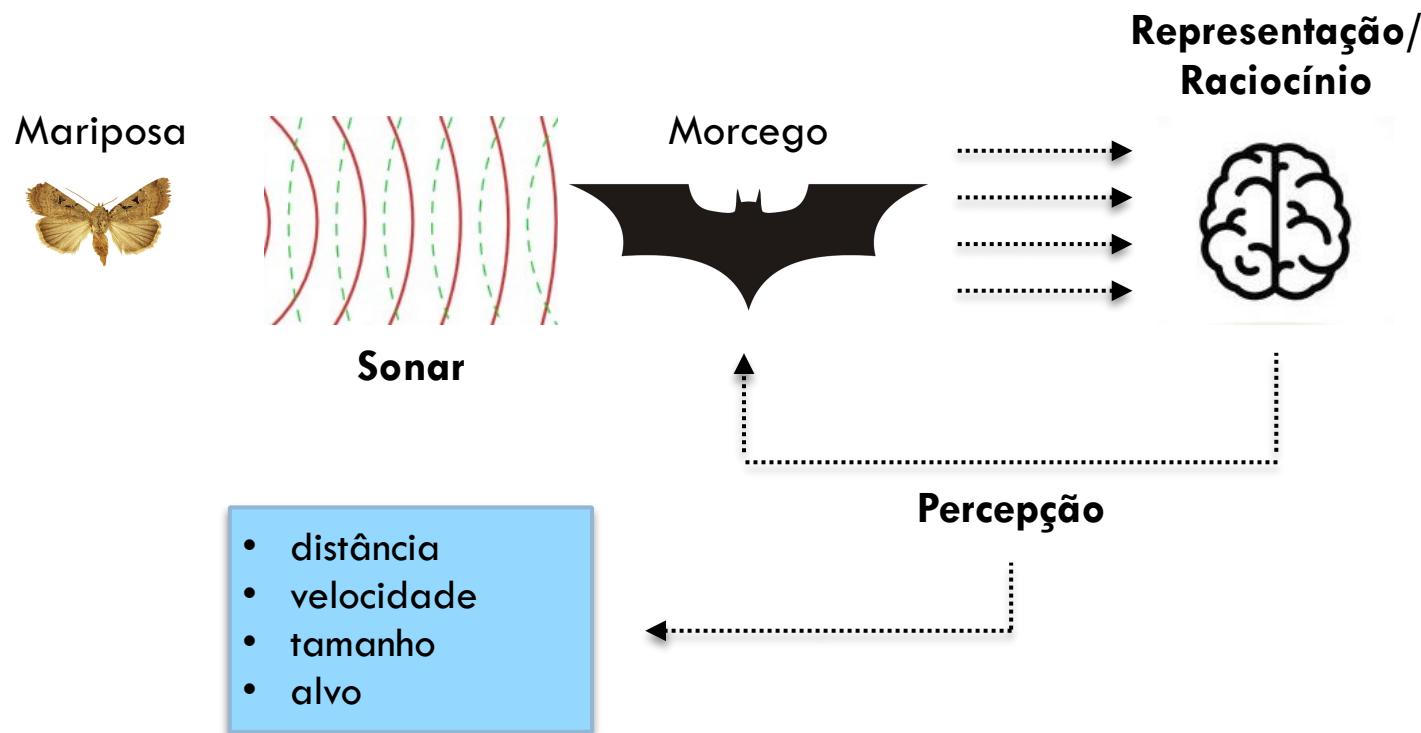
- Outro exemplo: sonar morcego



© Bat Conservation International, Inc.

Introdução

□ Sonar morcego



Introdução

Como o cérebro faz tudo isso?

Introdução

Como o cérebro faz tudo isso?

Plasticidade Sináptica!

Introdução

□ Plasticidade

Introdução

□ Plasticidade

- Característica nata do cérebro
- Existe uma estrutura/habilidade para aprender com **experiência**
- Capacidade do sistema nervoso se **adaptar** ao ambiente.

Introdução

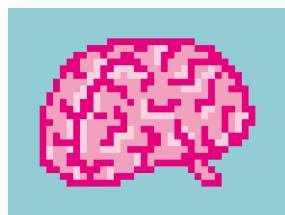
□ Plasticidade

- Característica nata do cérebro
- Existe uma estrutura/habilidade para aprender com **experiência**
- Capacidade do sistema nervoso se **adaptar** ao ambiente.

Importante:

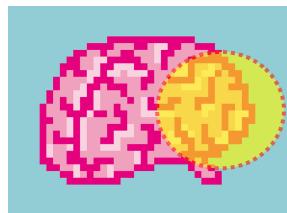
- Neurônios artificiais também apresentem as mesmas características dos neurônios biológicos.

Introdução



Cérebro

Introdução



Cérebro

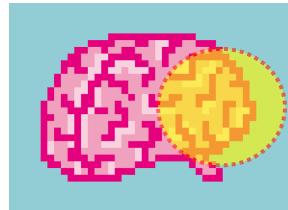
Introdução



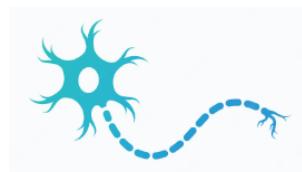
Cérebro

**Neurônio
biológico**

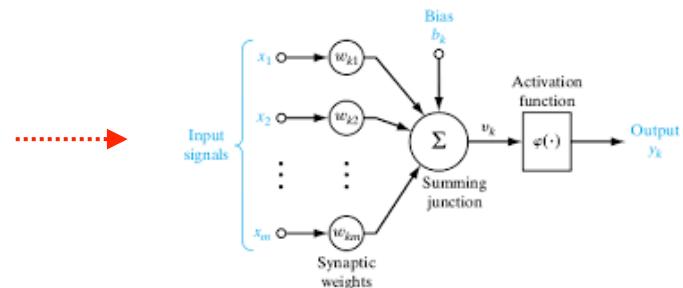
Introdução



Cérebro



Neurônio
biológico



Neurônio
artificial

Roteiro

- 1 Introdução**
- 2 Redes Neurais Artificiais**
- 3 Neurônio Artificial**
- 4 Modelagem de Redes Neurais**
- 5 Síntese / Próximas Aulas**
- 6 Referências**

Redes Neurais Artificiais

- **Rede Neural Artificial (RNA)**
 - é um modelo computacional
 - que mimetiza a forma como o cérebro realiza uma tarefa
 - por meio de neurônios artificiais e algoritmos de aprendizado

Redes Neurais Artificiais

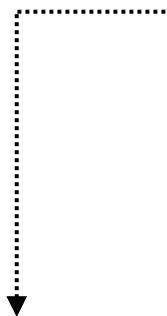
□ **Rede Neural Artificial (RNA)**

- é um modelo computacional
- que mimetiza a forma como o cérebro realiza uma tarefa
- por meio de neurônios artificiais e algoritmos de aprendizado

Definição: sistema de processamento massivamente paralelo e distribuído, construído com unidades de processamento simples, que tem uma propensão natural de armazenar conhecimento por meio de experiência e torná-lo disponível para uso.

Redes Neurais Artificiais

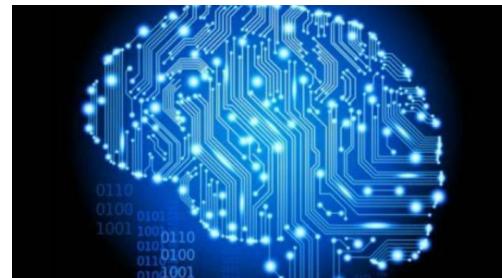
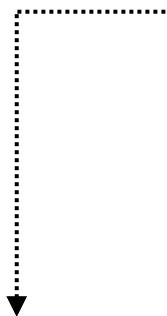
Adquirem o
conhecimento



Redes Neurais Artificiais

Redes Neurais Artificiais

Adquirem o
conhecimento



Redes Neurais Articiais

Processo de
Aprendizado

Redes Neurais Artificiais

Adquirem o
conhecimento



Redes Neurais Articiais

Armazemam o
conhecimento

Processo de
Aprendizado

Redes Neurais Artificiais

Adquirem o conhecimento



Redes Neurais Artificiais

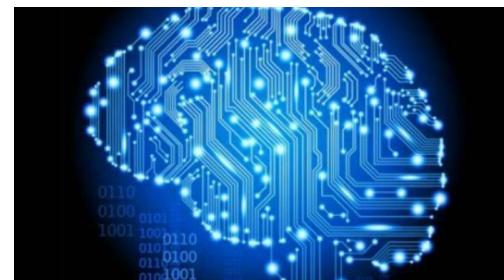
Armazenam o conhecimento

Processo de Aprendizado

Pesos Sinápticos

Redes Neurais Artificiais

Adquirem o conhecimento



Redes Neurais Articiais

Armazenam o conhecimento

Processo de Aprendizado

Conhecimento

Pesos Sinápticos

Redes Neurais Artificiais



Adquirem o conhecimento
aprendizado e armazenam-o na forma dos pesos sinápticos (vetor/matriz de números reais)

Processo de Aprendizado

Conhecimento

Pesos Sinápticos

Redes Neurais Artificiais

- Replicar a função biológica



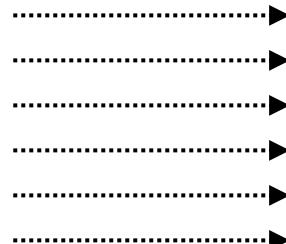
ave

Redes Neurais Artificiais

- Replicar a função biológica



ave



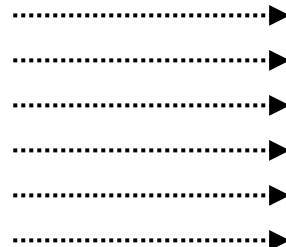
avião

Redes Neurais Artificiais

- Replicar a função biológica



ave

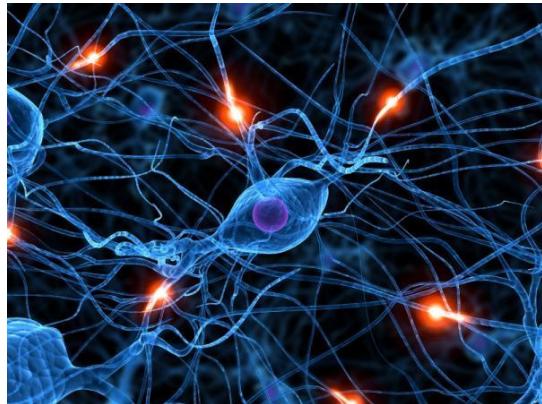


avião

Frequentemente, nós seres humanos, desenvolvemos tecnologias nos inspirando em coisas da natureza.

Redes Neurais Artificiais

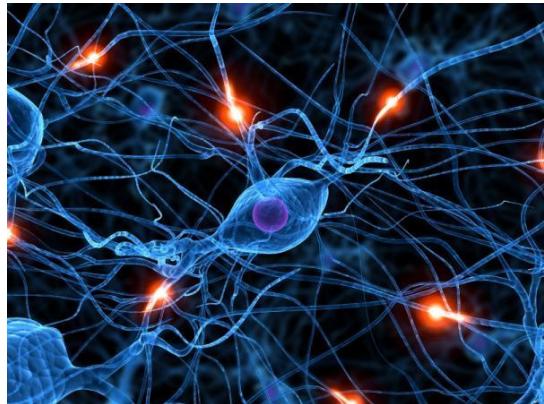
- Replicar a função biológica



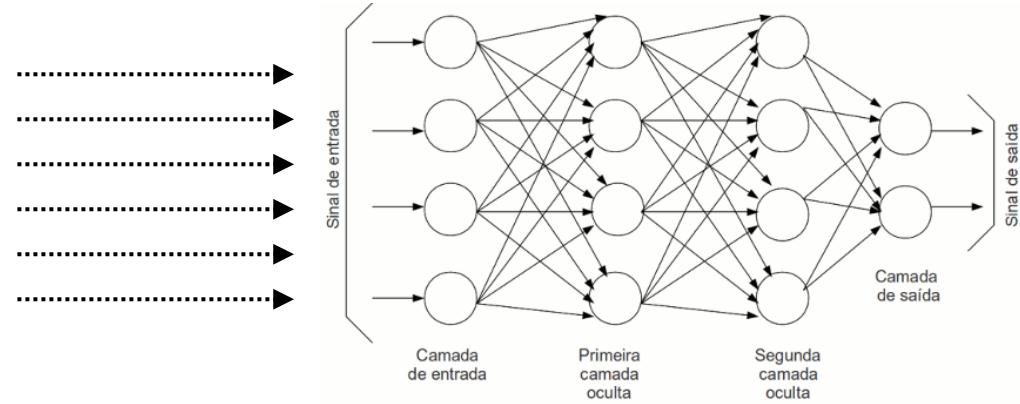
Rede neural biológica

Redes Neurais Artificiais

- Replicar a função biológica



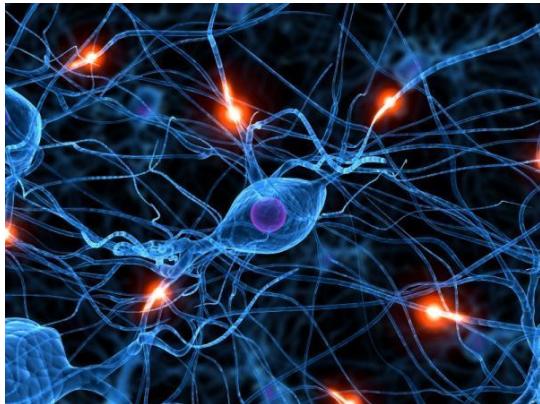
Rede neural biológica



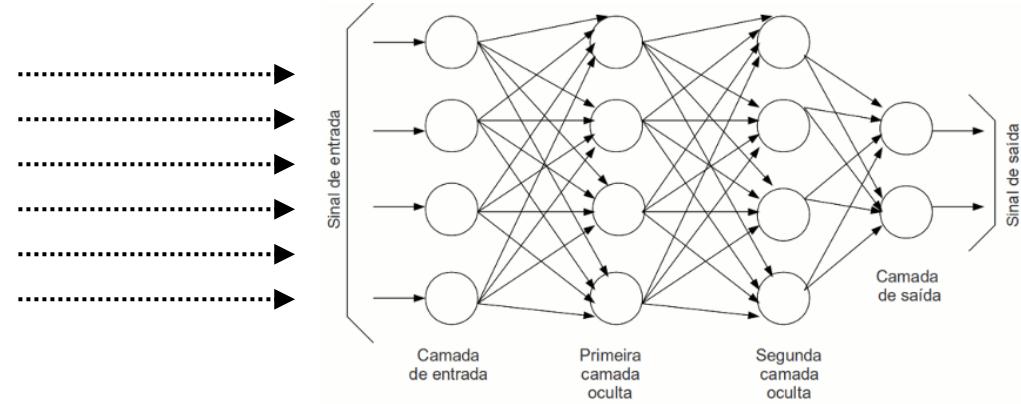
Rede neural artificial

Redes Neurais Artificiais

- Replicar a função biológica



Rede neural biológica



Rede neural artificial

O mesmo acontece observando o cérebro,
gerando as RNAs.

Aprendizado

E como as RNAs **aprendem?**

Aprendizado

- Algoritmo de Aprendizado:
 - cuja função é **modificar os pesos sinápticos (intensidade dos sinais)** da rede, de maneira a ajustá-los para cumprir o objetivo desejado

Aprendizado

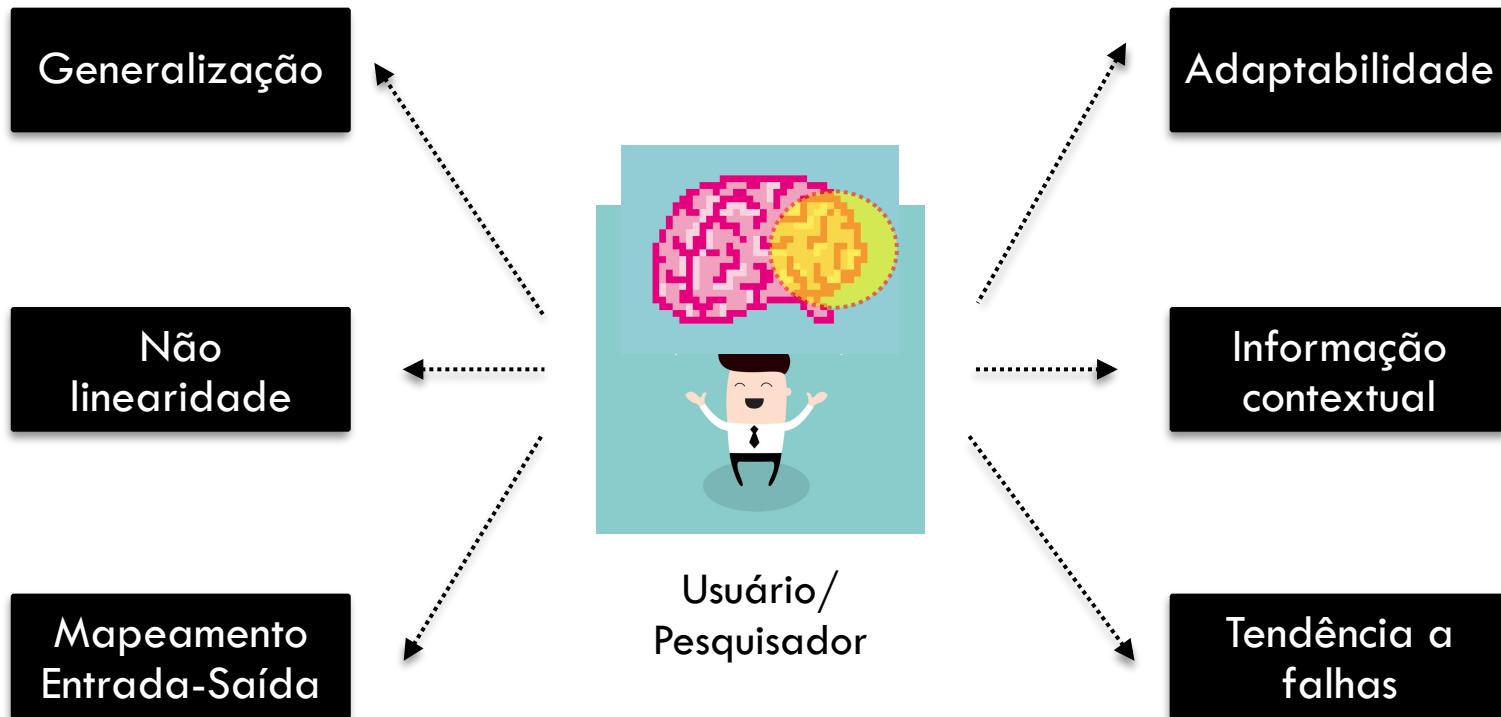
- Algoritmo de Aprendizado:
 - cuja função é **modificar os pesos sinápticos (intensidade dos sinais)** da rede, de maneira a ajustá-los para cumprir o objetivo desejado
- Também é possível que uma rede modifique sua própria **topologia (estrutura)** durante o aprendizado
 - quando células morrem, novas conexões são criadas
 - **Exemplo:** pessoas q sofrem lesões graves, mas reaprendem a executar algumas tarefas

Características



Usuário/
Pesquisador

Características



Características

Generalização

As RNAs tem a capacidade de **produzir respostas razoáveis para entradas/dados desconhecidos** (boa aproximação para problemas complexos)

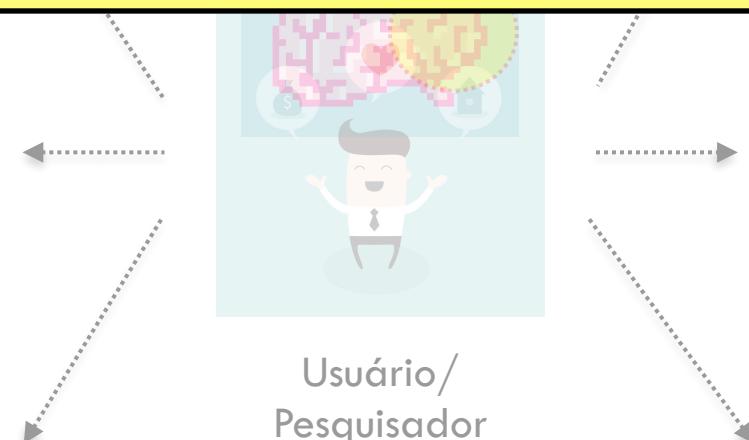
Não
linearidade

Informação
contextual

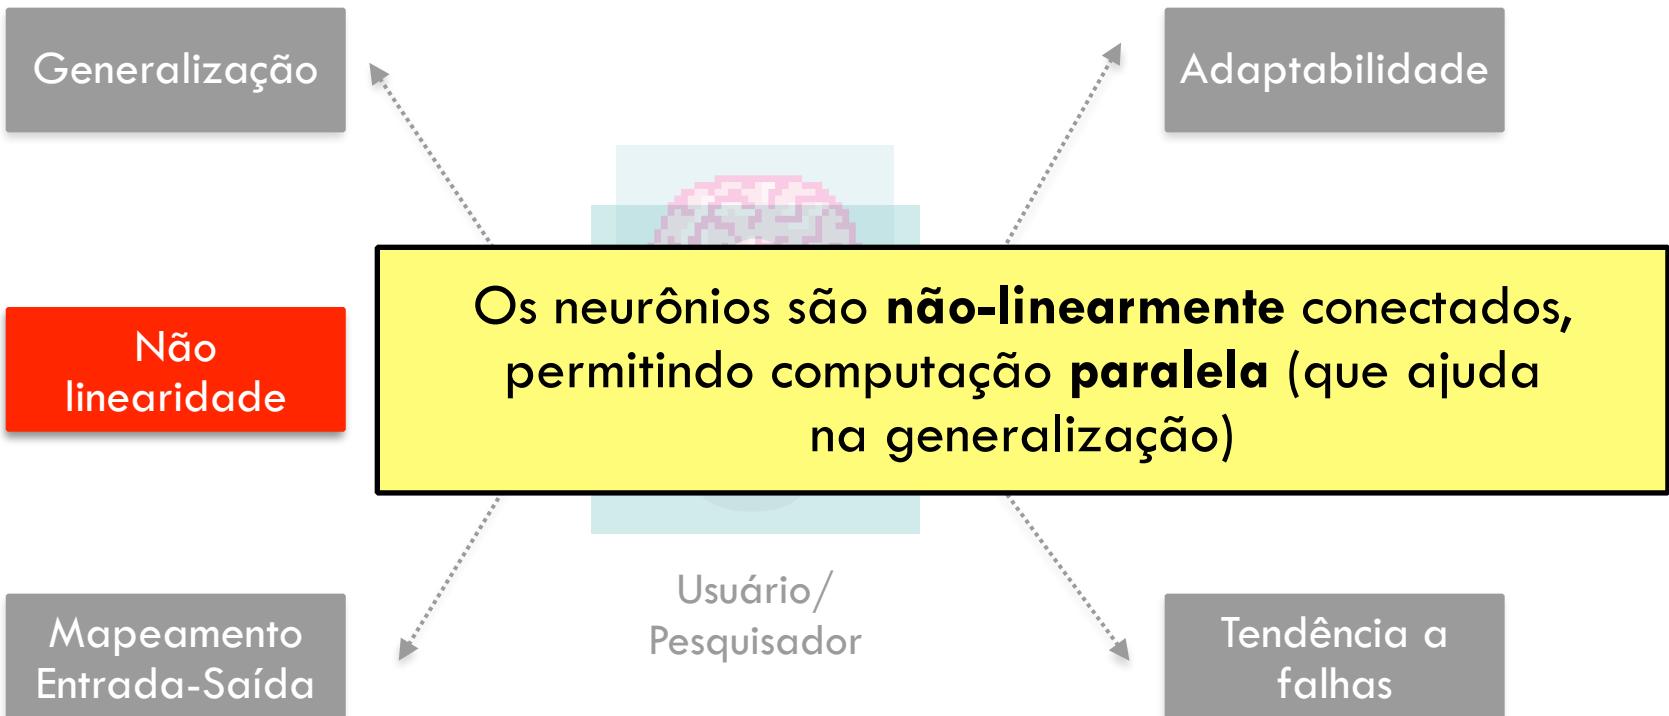
Mapeamento
Entrada-Saída

Usuário/
Pesquisador

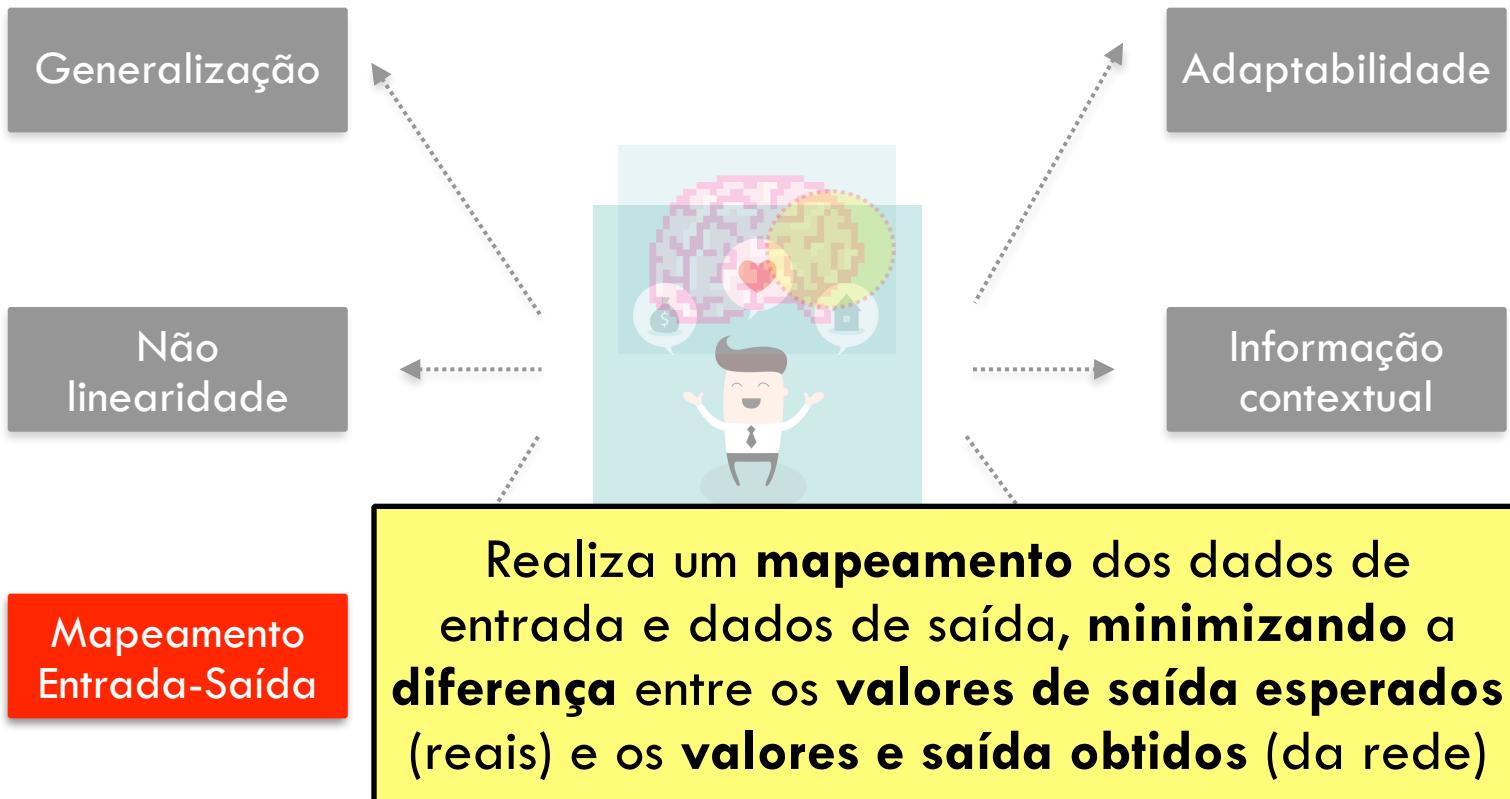
Tendência a
falhas



Características



Características



Características

Podemos usar RNAs em **problemas similares**, demandando apenas **poucas mudanças**

Adaptabilidade

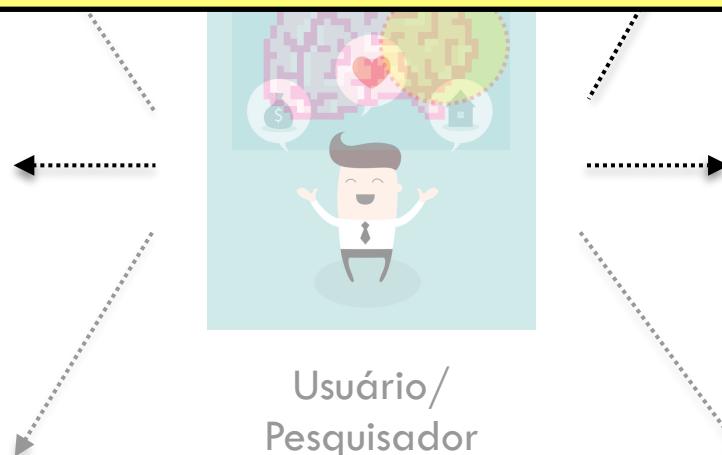
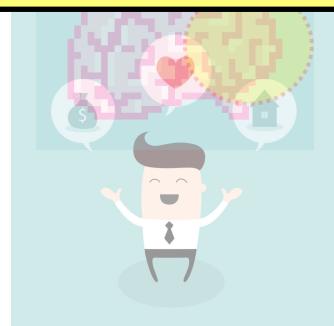
Não
linearidade

Informação
contextual

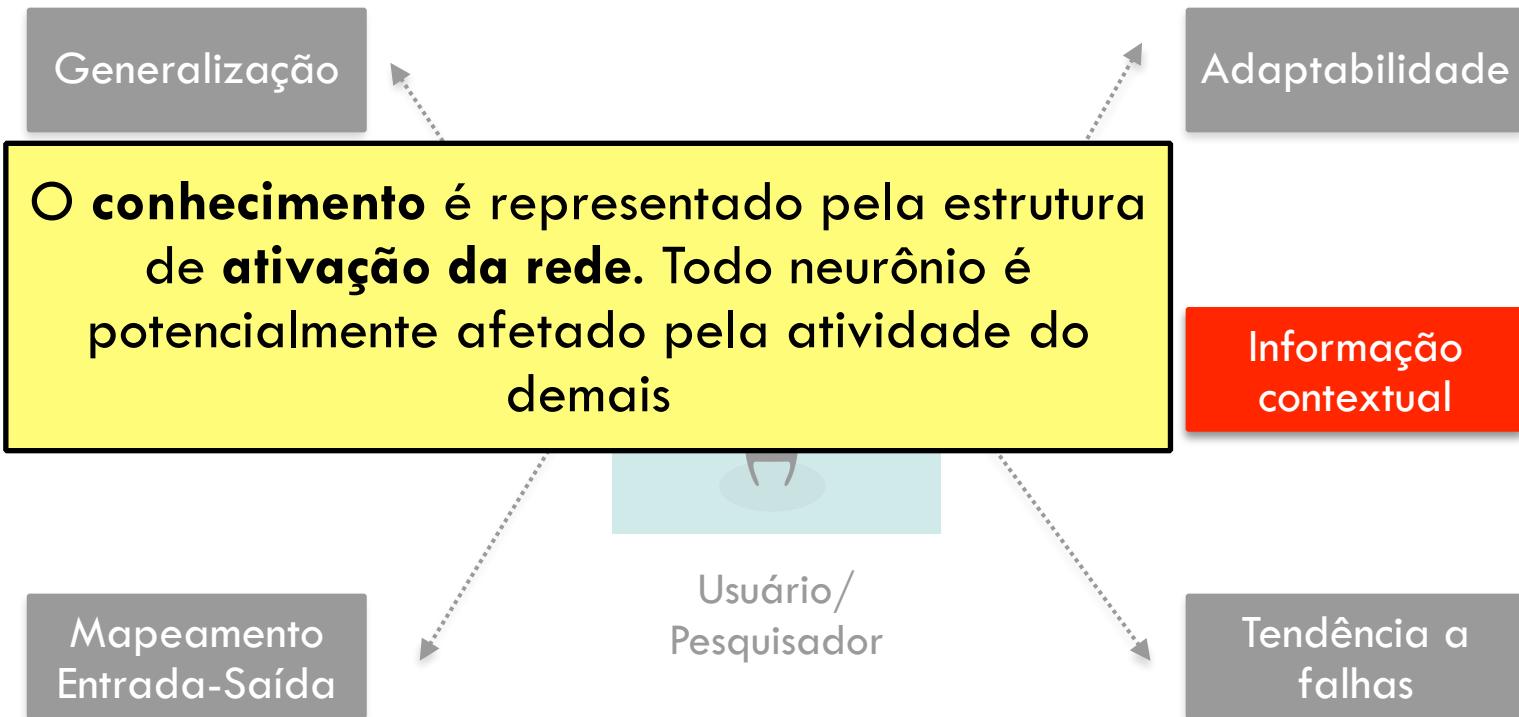
Mapeamento
Entrada-Saída

Tendência a
falhas

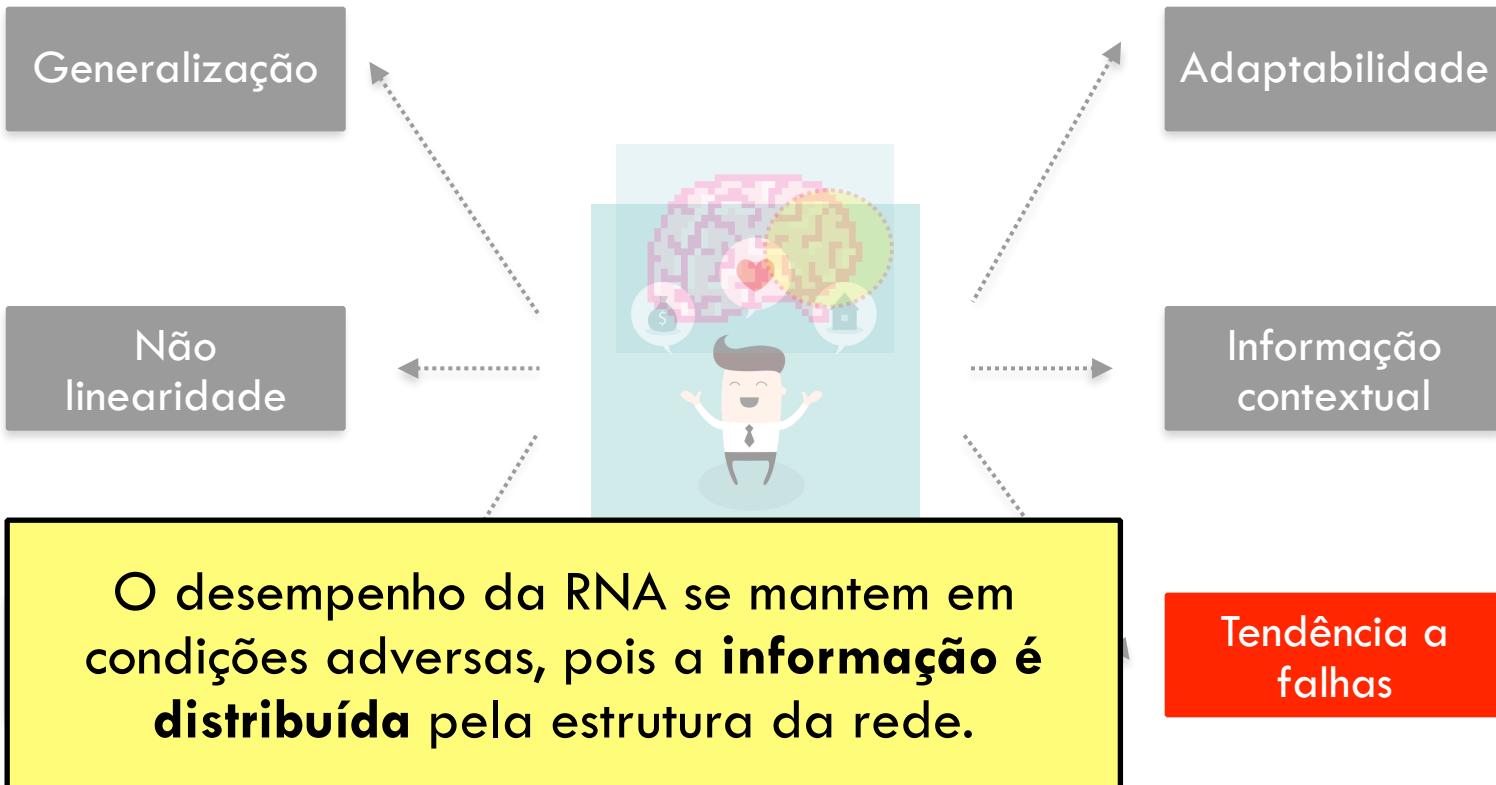
Usuário/
Pesquisador



Características



Características



Roteiro

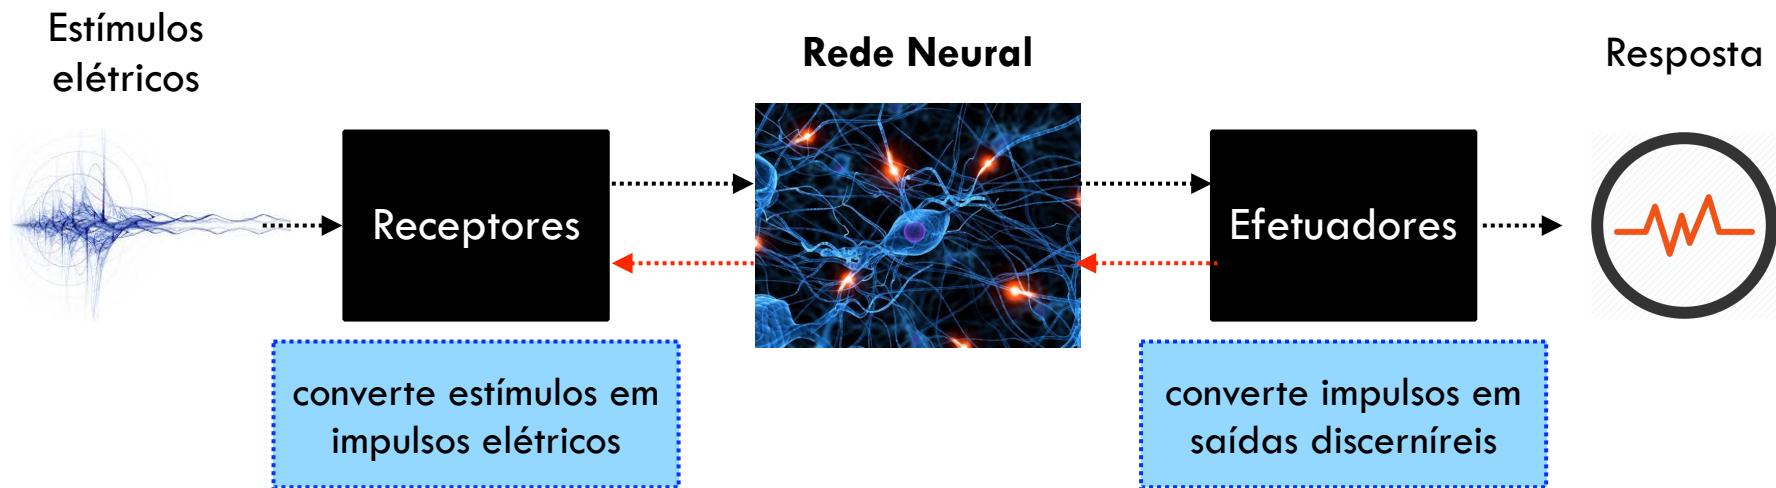
- 1 Introdução**
- 2 Redes Neurais Artificiais**
- 3 Neurônio Artificial**
- 4 Modelagem de Redes Neurais**
- 5 Síntese / Próximas Aulas**
- 6 Referências**

Neurônio Artificial

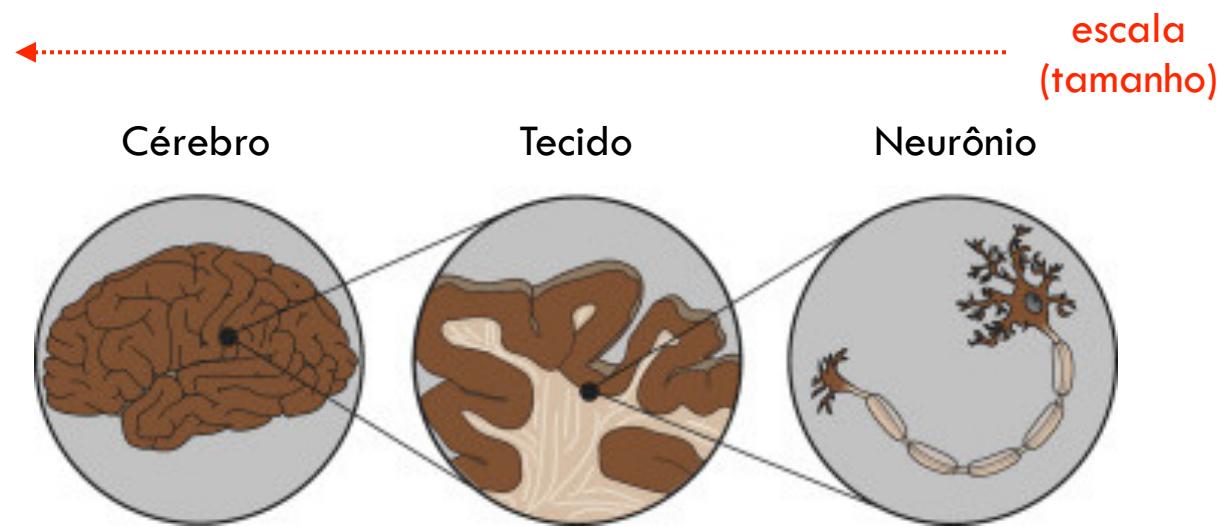
Mas como iremos codificar/representar um
neurônio artificial?

Vamos nos inspirar na biologia :)

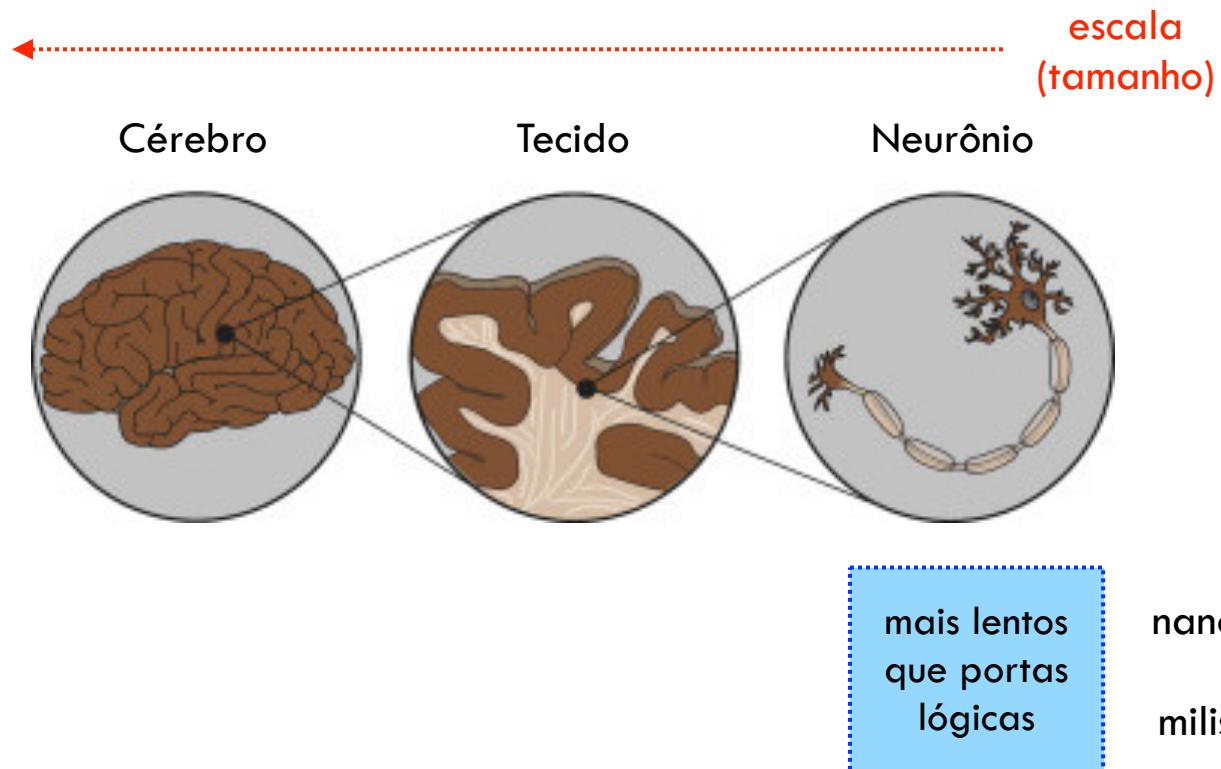
Cérebro Humano



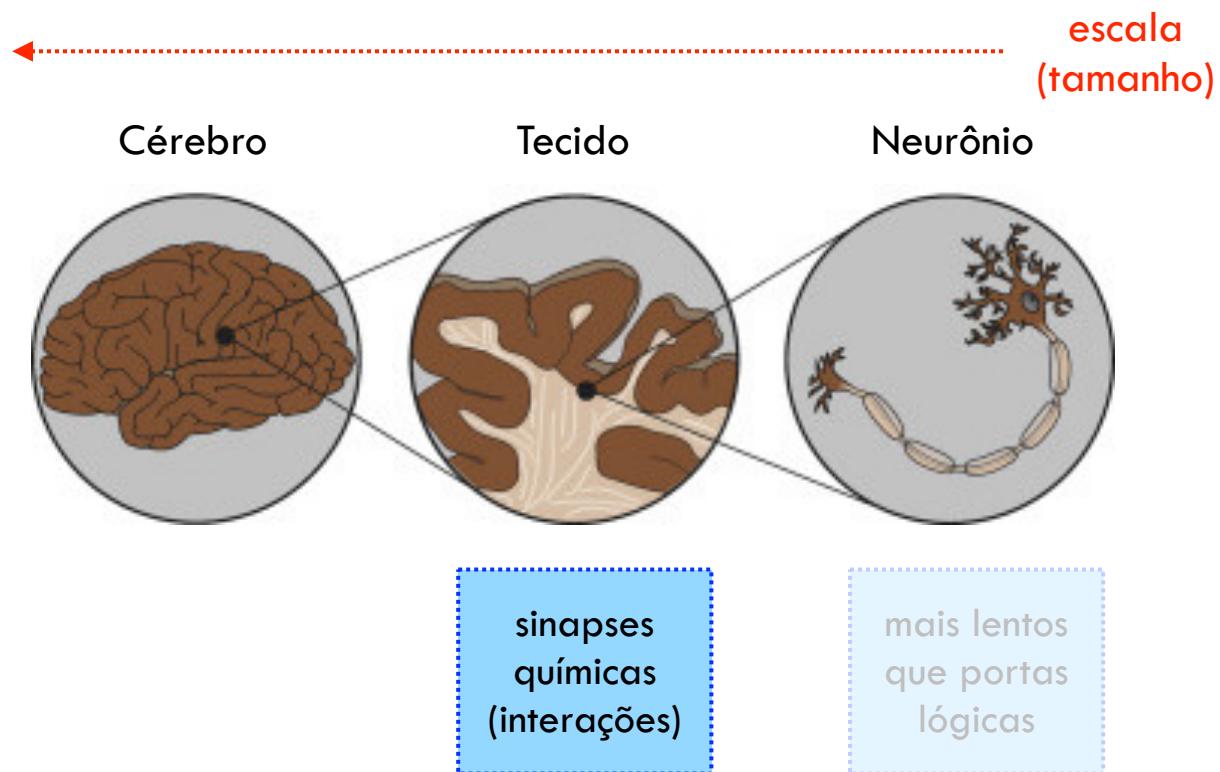
Cérebro Humano



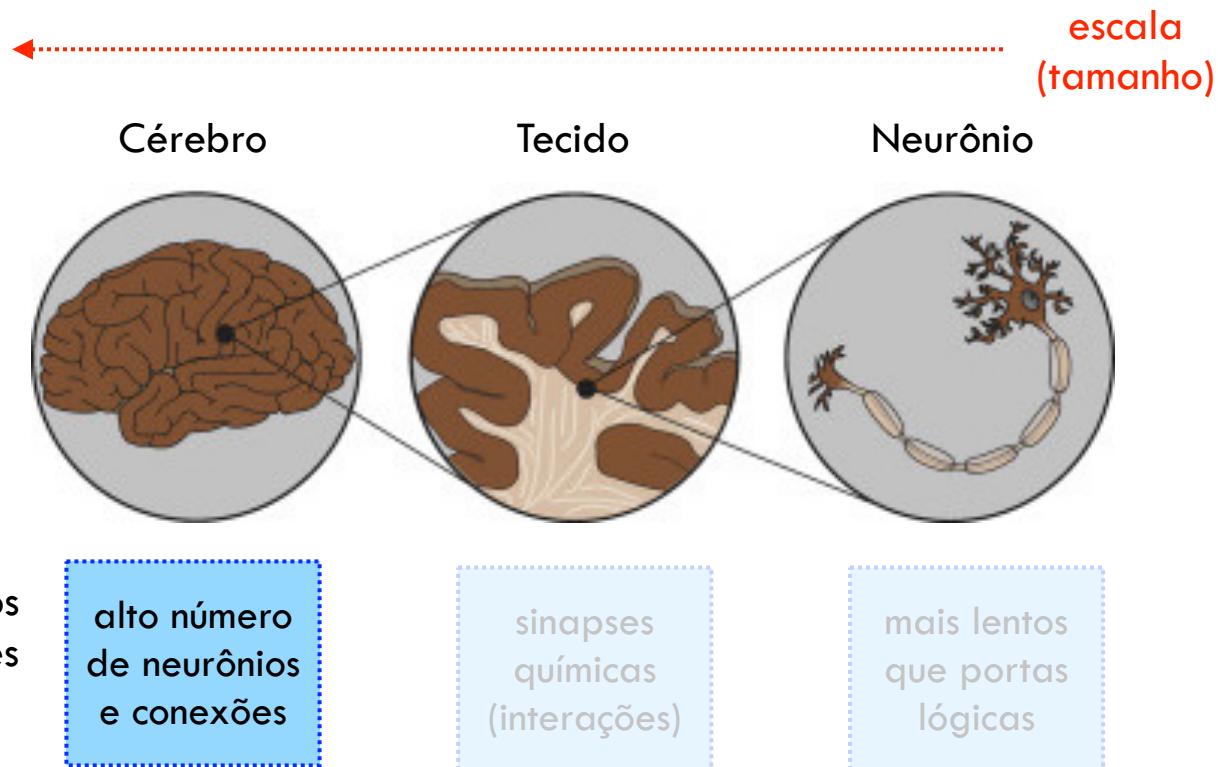
Cérebro Humano



Cérebro Humano

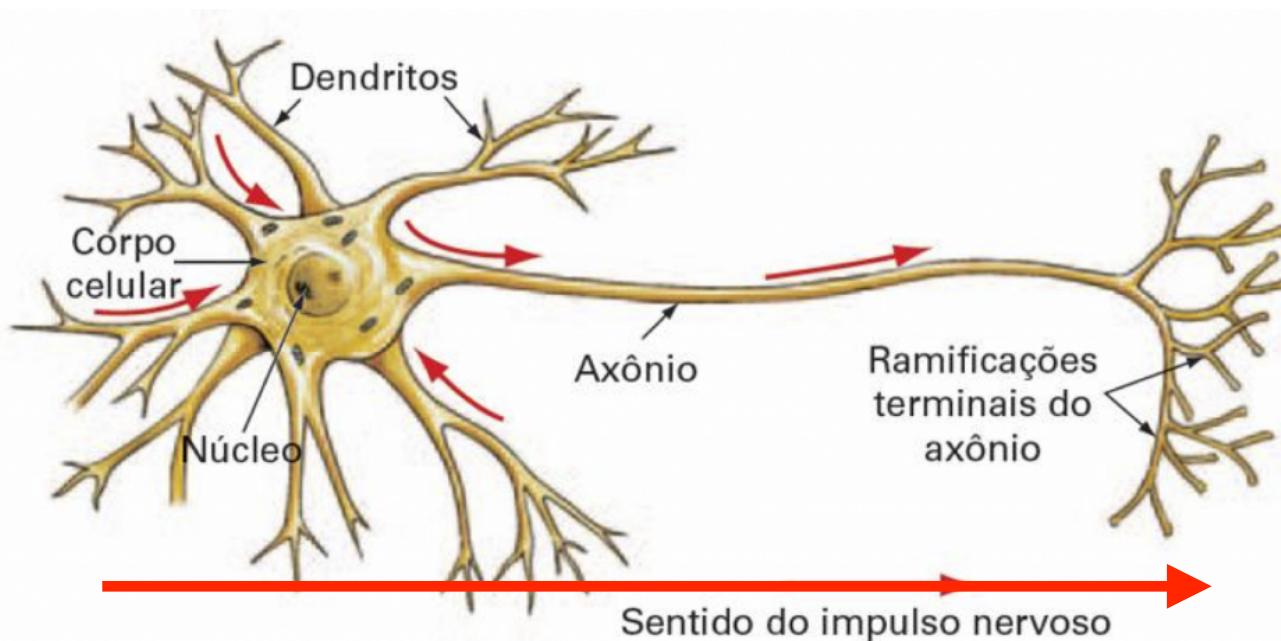


Cérebro Humano



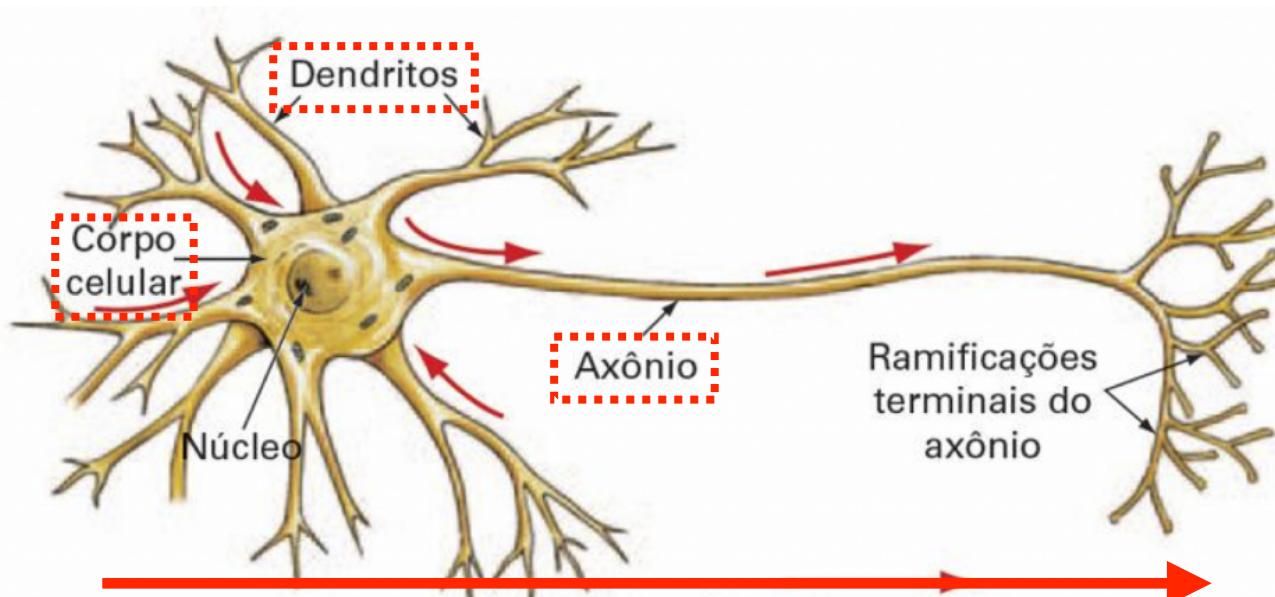
Cérebro Humano

□ Neurônio biológico



Cérebro Humano

☐ Neurônio biológico



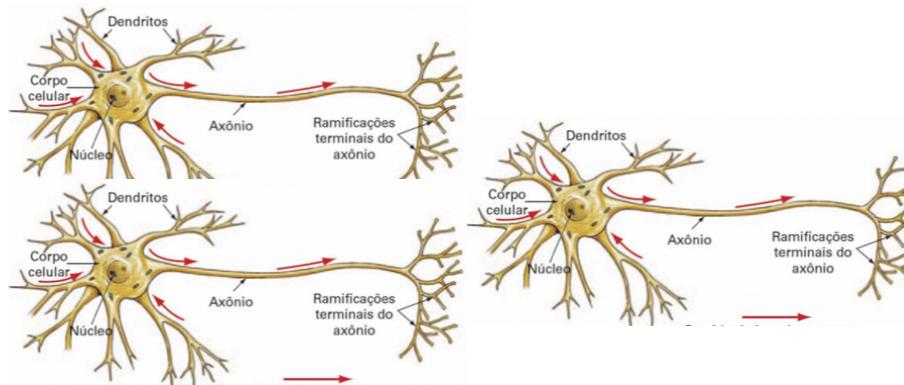
Axônios: linhas de transmissão

Dendritos: zonas de recepção

Corpo Celular (Soma): processamento dos sinais

Cérebro Humano

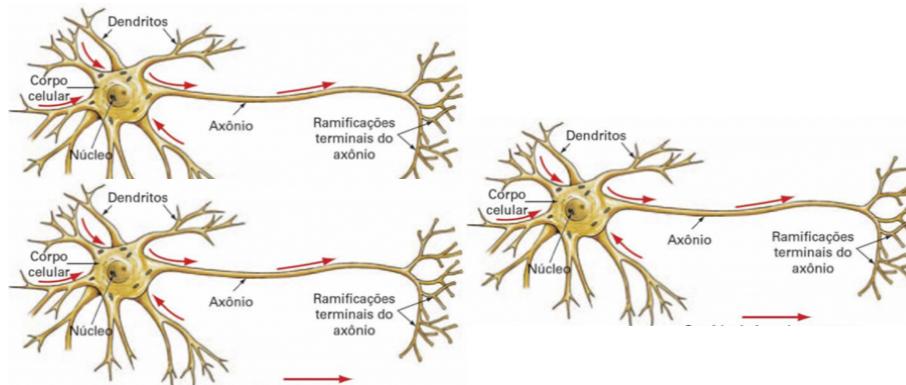
□ Neurônio biológico



Sentido do sinal

Cérebro Humano

□ Neurônio biológico

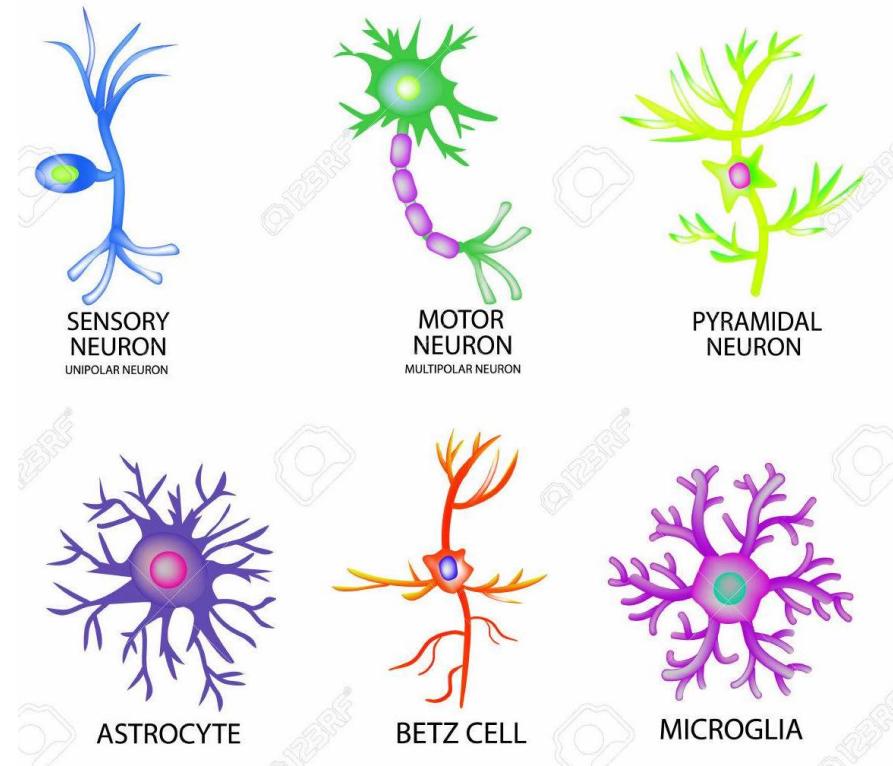


Sentido do sinal

As ramificações do **axônio** de um neurônio se conectam nos **dendritos** de outro neurônio, e assim por diante ...

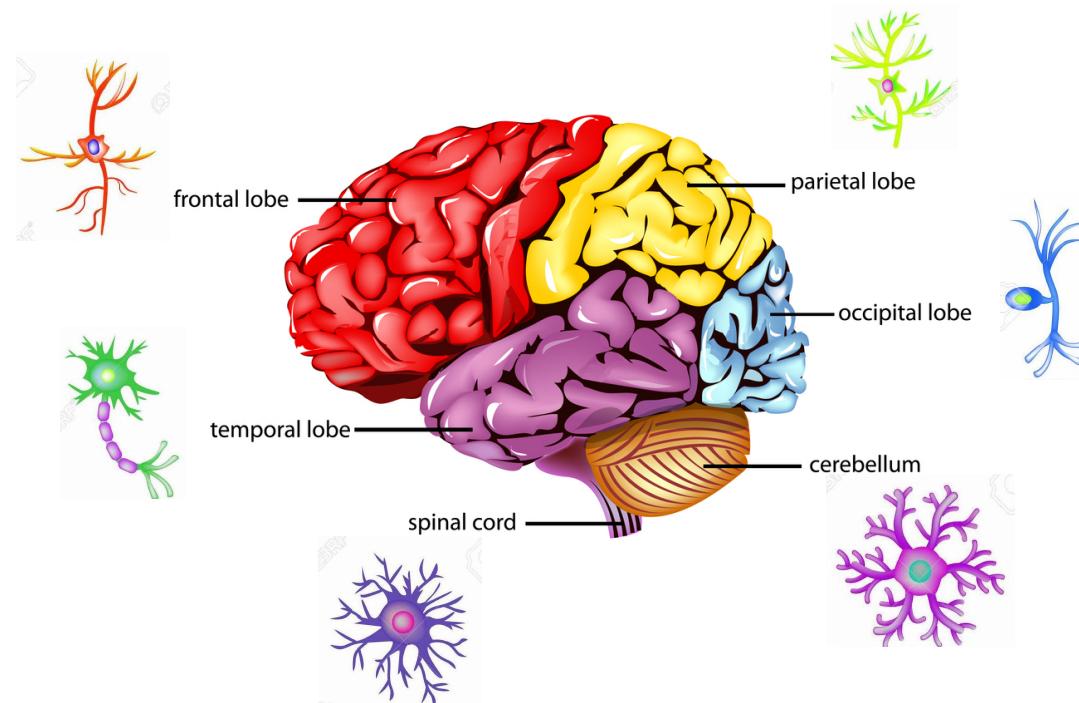
Cérebro Humano

- Porém existem diferentes tipos de neurônios



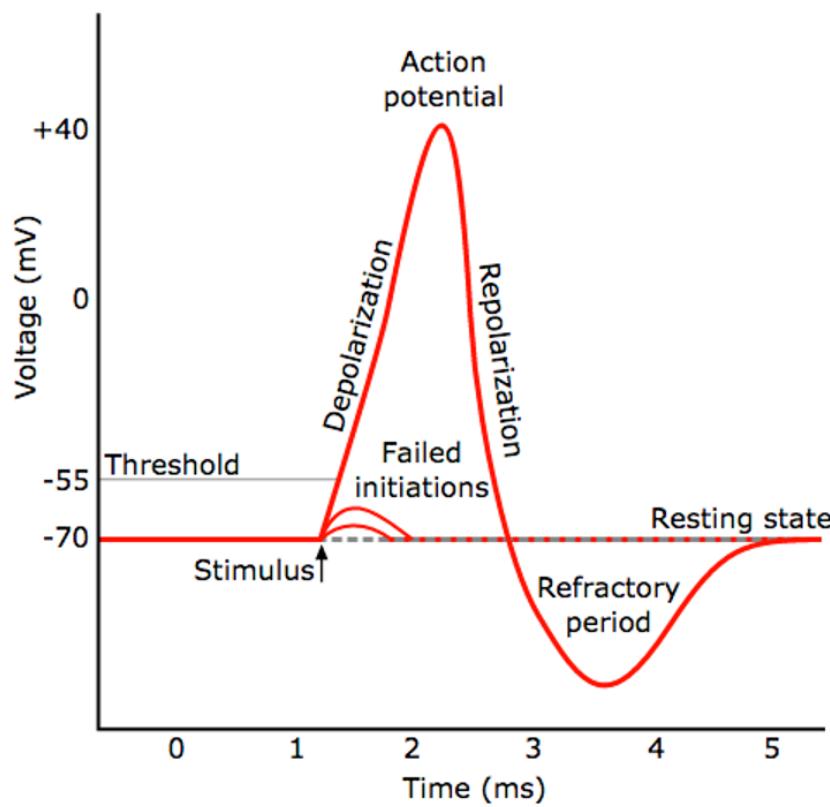
Cérebro Humano

- ... localizados em diferentes regiões do cérebro



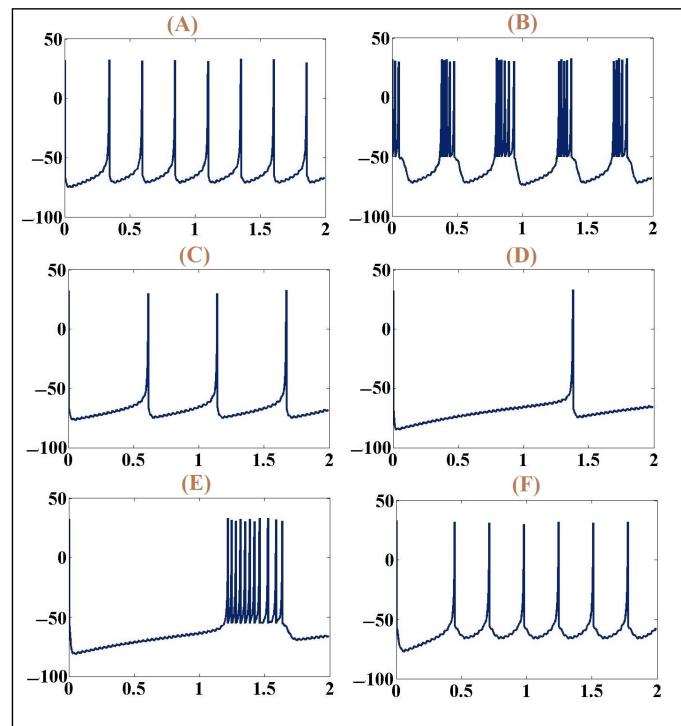
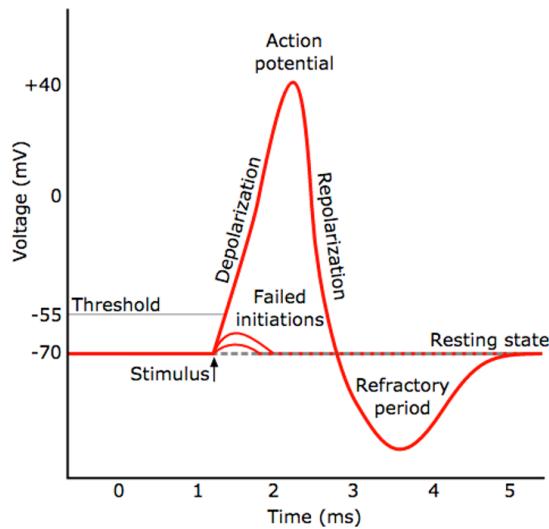
Cérebro Humano

- Potencial de ativação do neurônio



Cérebro Humano

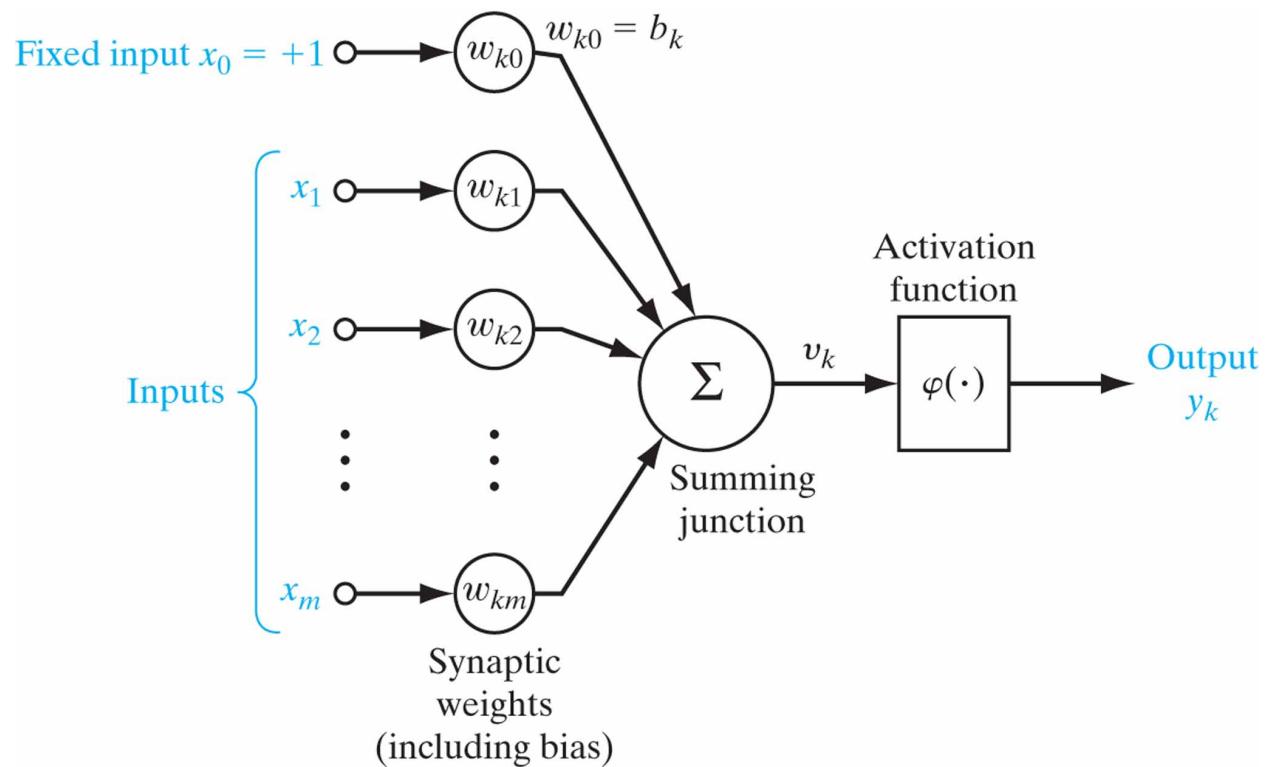
□ Potencial de ativação do neurônio



Neurônio Artificial

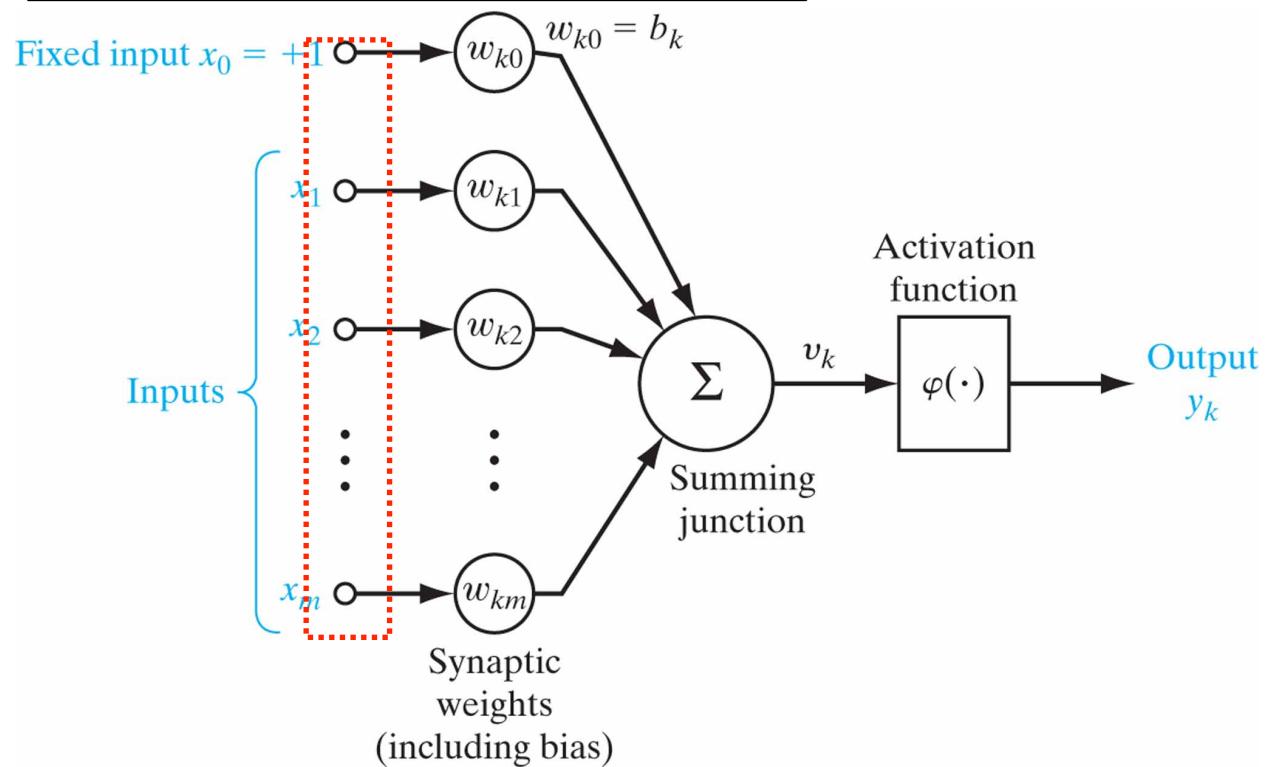
Logo, computacionalmente temos:

Neurônio Artificial

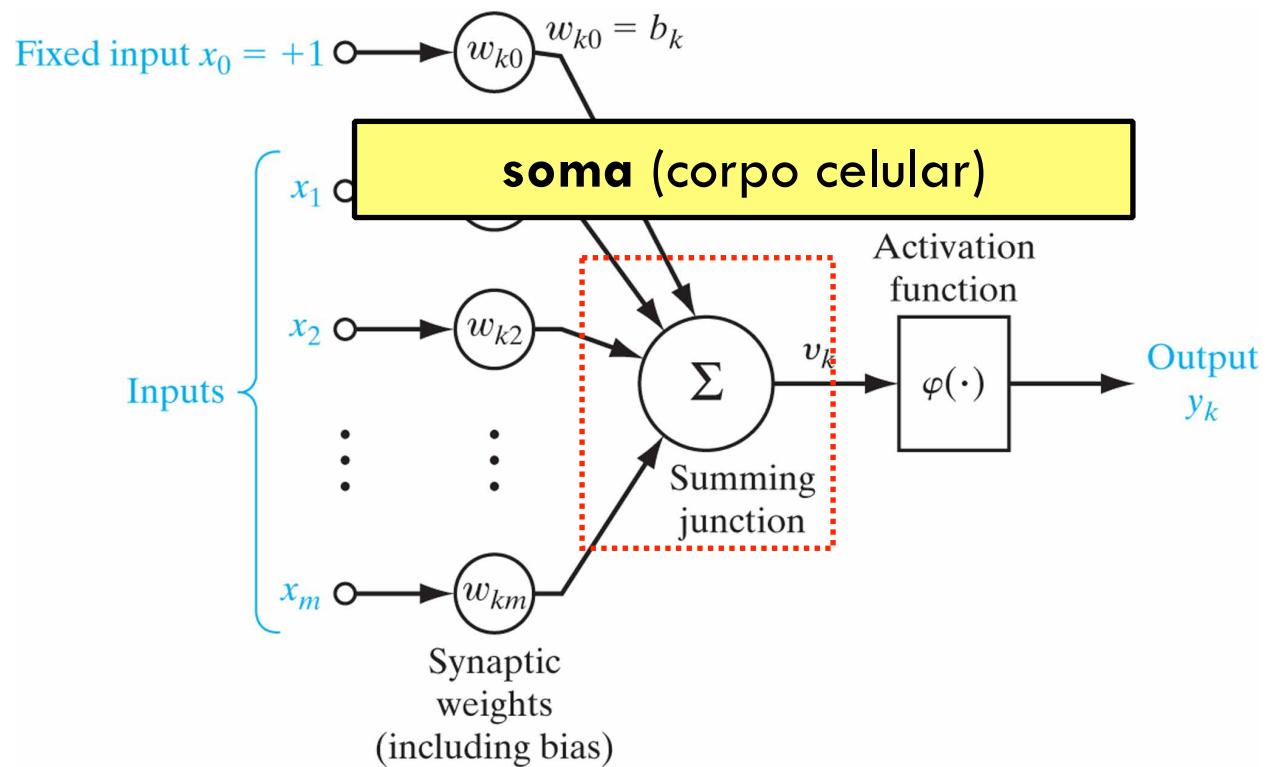


Neurônio Artificial

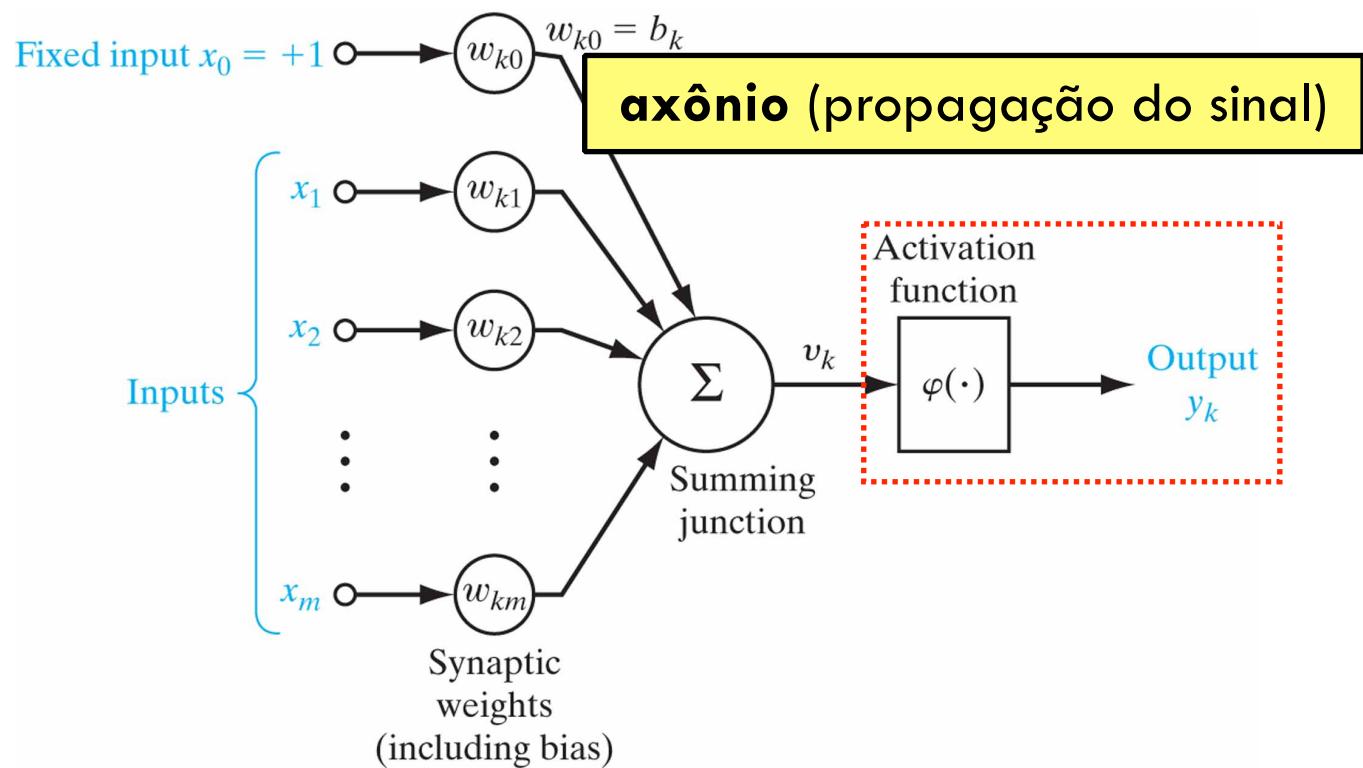
Dendritos (recepção do sinal)



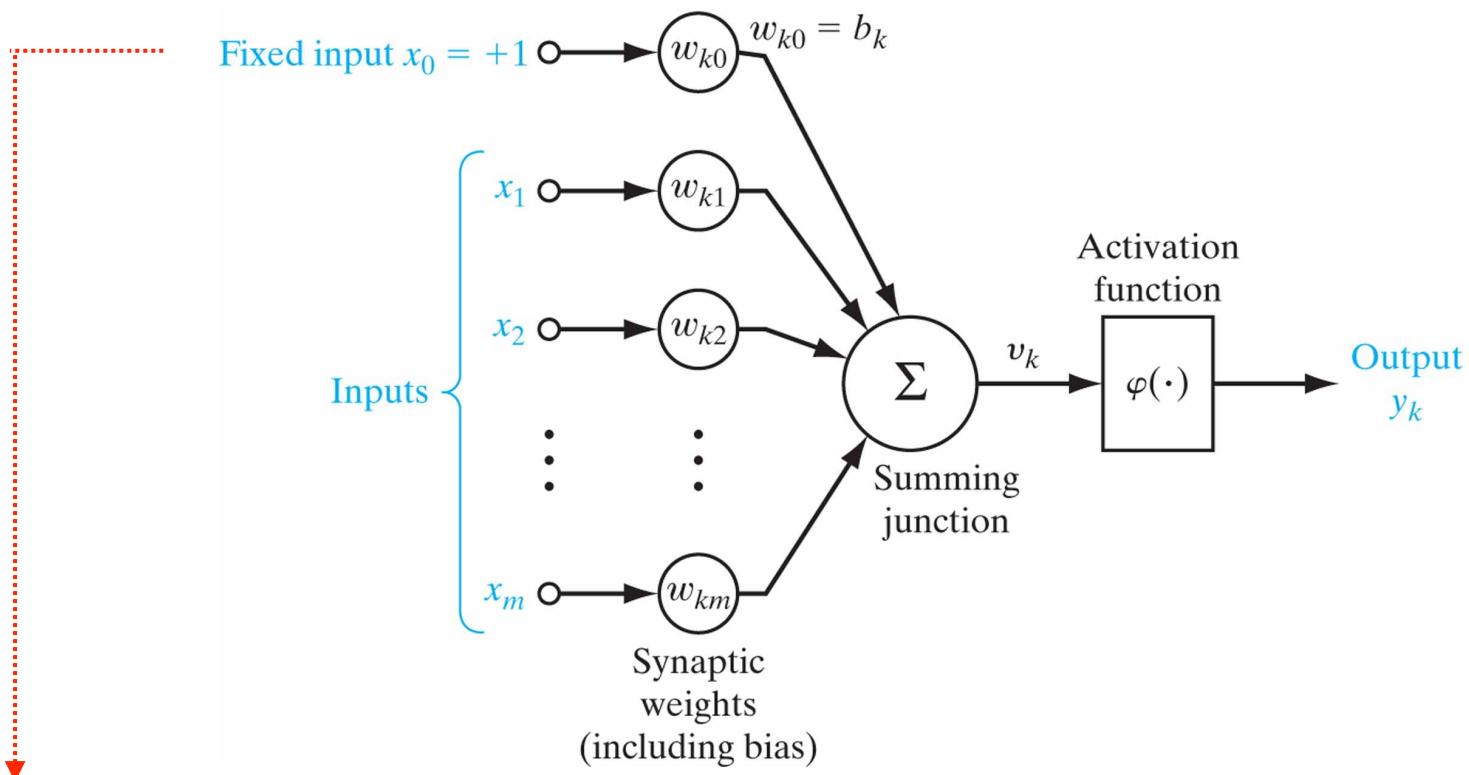
Neurônio Artificial



Neurônio Artificial



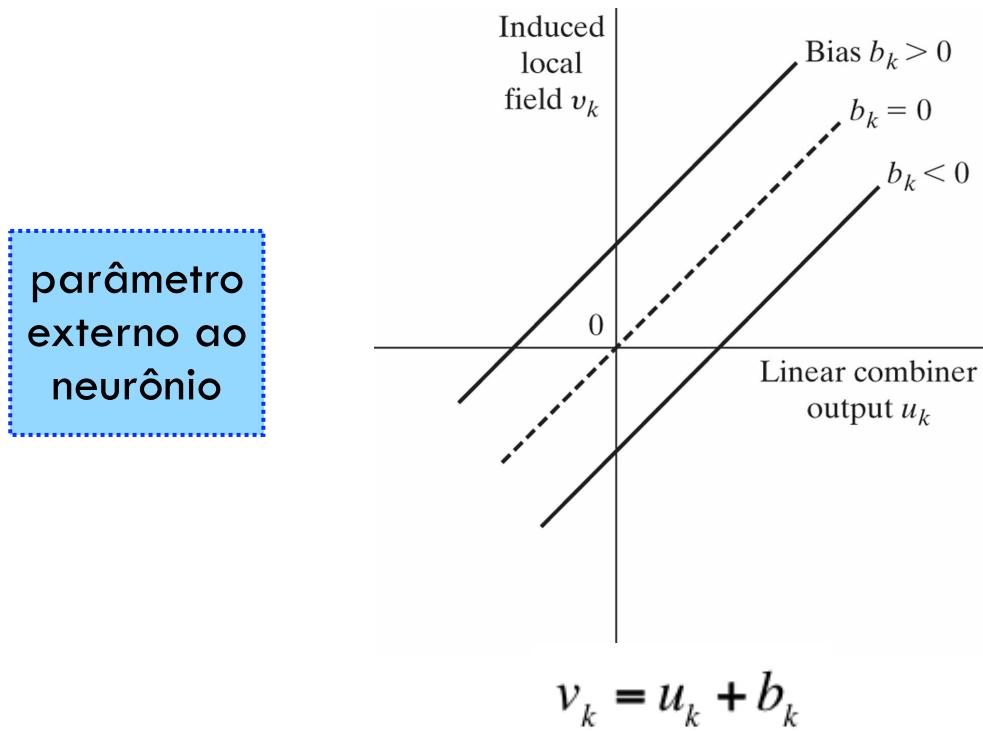
Neurônio Artificial



- o **Bias (viés)** tem a função de aumentar ou diminuir a entrada da função de ativação

Neurônio Artificial

- **Bias:** efeito de aplicar uma transformação em u_k , mantendo colinearidade



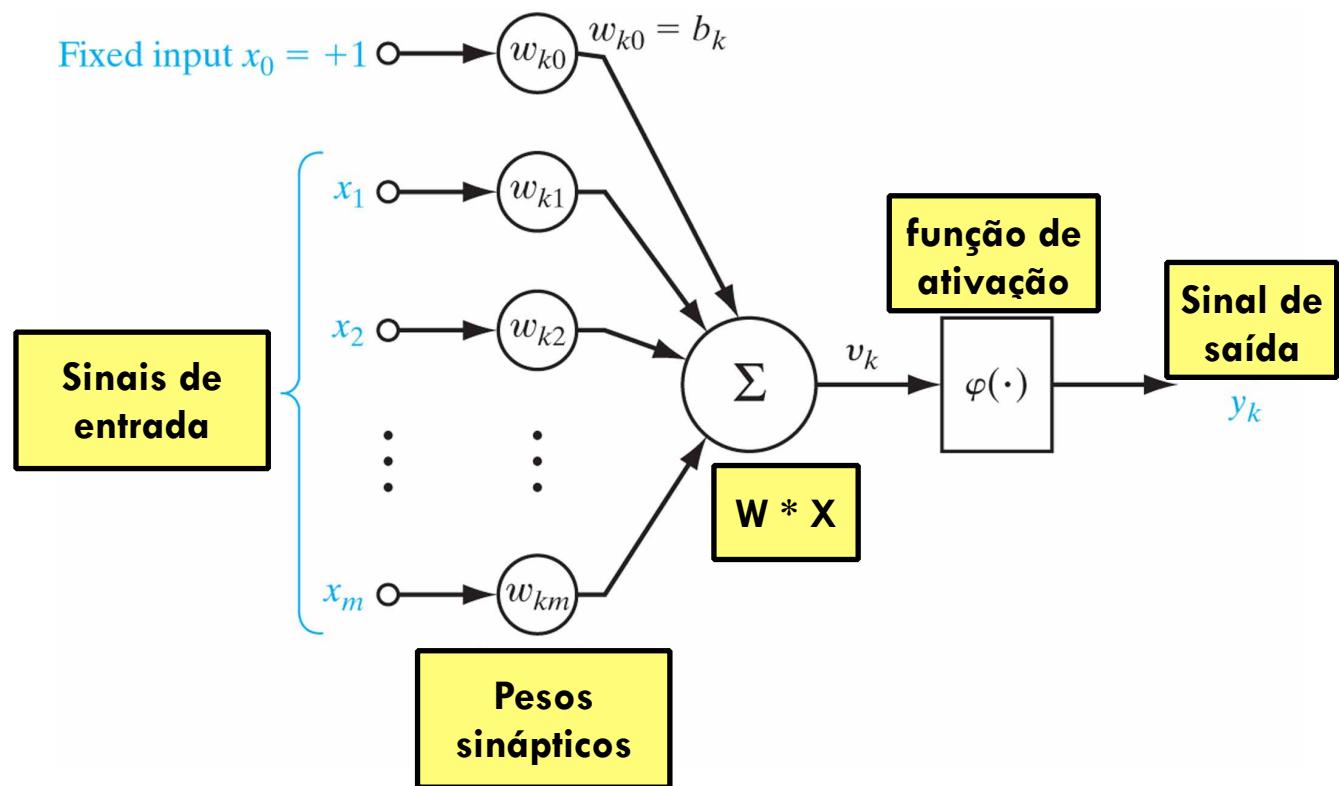
Neurônio Artificial

- Matematicamente:

$$v_k = \sum_{j=0}^m w_{kj}x_j \quad \text{e} \quad y_k = \varphi(v_k)$$

- X são os sinais de entrada
- W são os pesos sinápticos do neurônio k
- v_k é a combinação linear de W (pesos) e X (entradas)
- $\varphi(.)$ é a função de ativação (sinal propagado)
- y_k é a saída do neurônio

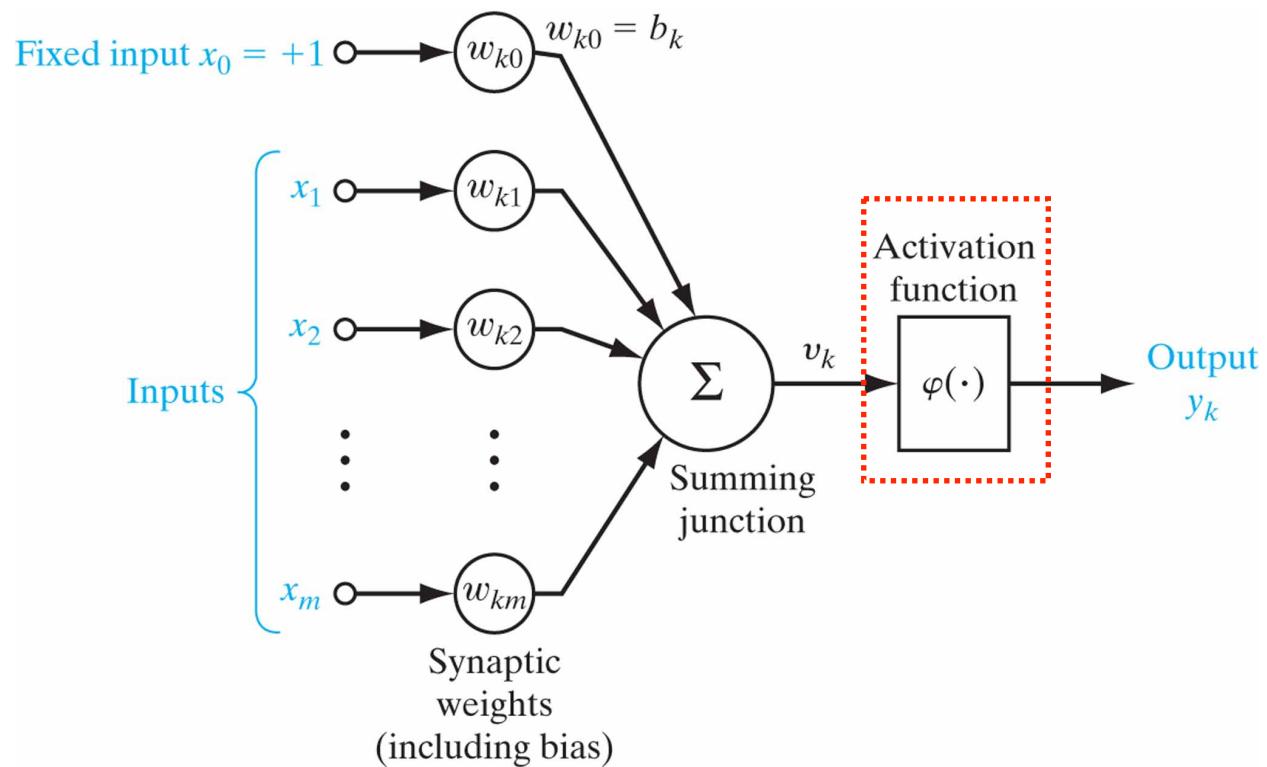
Neurônio Artificial



Roteiro

- 1 Introdução**
- 2 Redes Neurais Artificiais**
- 3 Neurônio Artificial**
- 4 Modelagem de Redes Neurais**
- 5 Síntese / Próximas Aulas**
- 6 Referências**

Neurônio Artificial



Funções de ativação

- função de ativação, $\varphi(v)$, define a saída do neurônio em termos de v :

- função degrau:**
$$\varphi(v) = \begin{cases} 1 & \text{se } v \geq 0 \\ 0 & \text{se } v < 0 \end{cases}$$

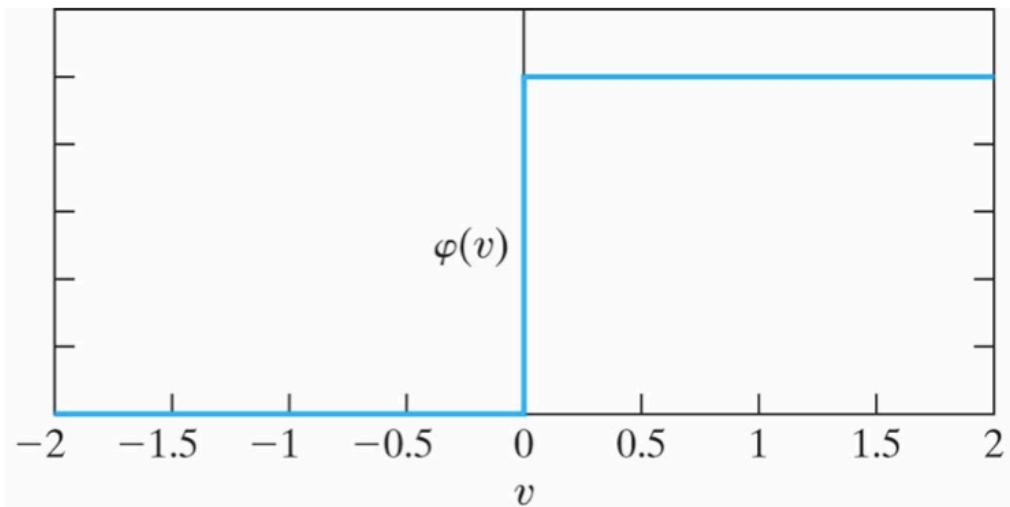
- a saída do neurônio k :

$$y_k = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{se } v_k < 0 \end{cases} \quad \text{sendo} \quad v_k = \sum_{j=1}^m w_{kj}x_j + b_k$$

Funções de ativação

- Neurônio de McCulloch-Pitts (1943):

$$\varphi(v) = \begin{cases} 1 & \text{se } v \geq 0 \\ 0 & \text{se } v < 0 \end{cases}$$



Funções de ativação

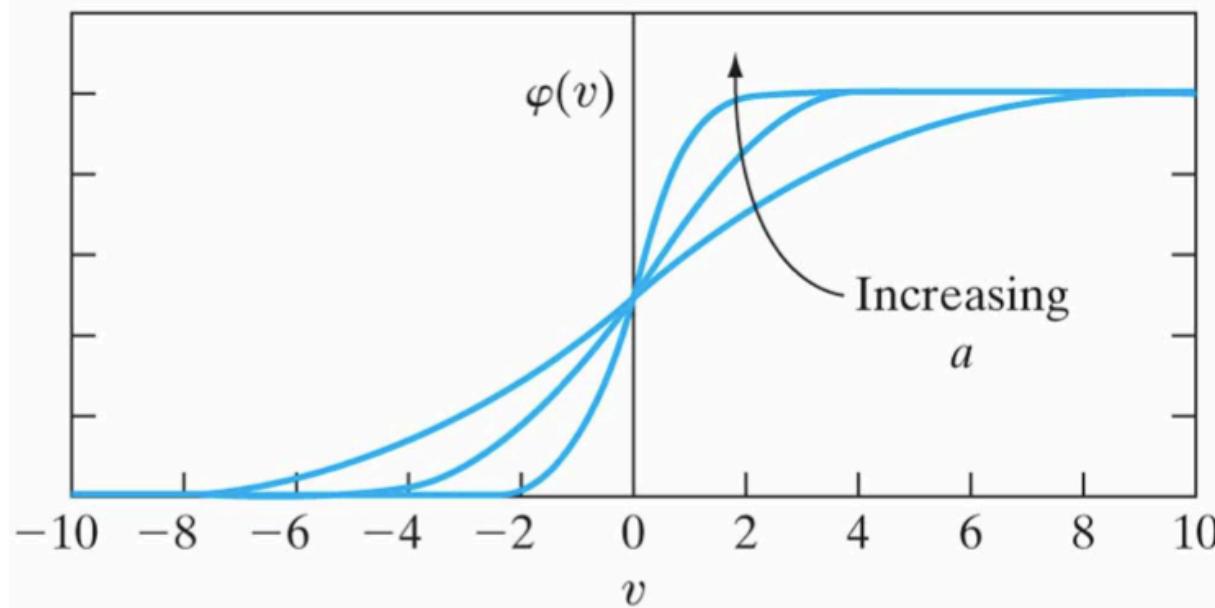
- **Função sigmoidal** : forma mais comumente utilizada.
 - exemplo: função logística

$$\varphi(v) = \frac{1}{1 + \exp(-av)}$$

- o parâmetro **a** define a inclinação da função sigmoidal

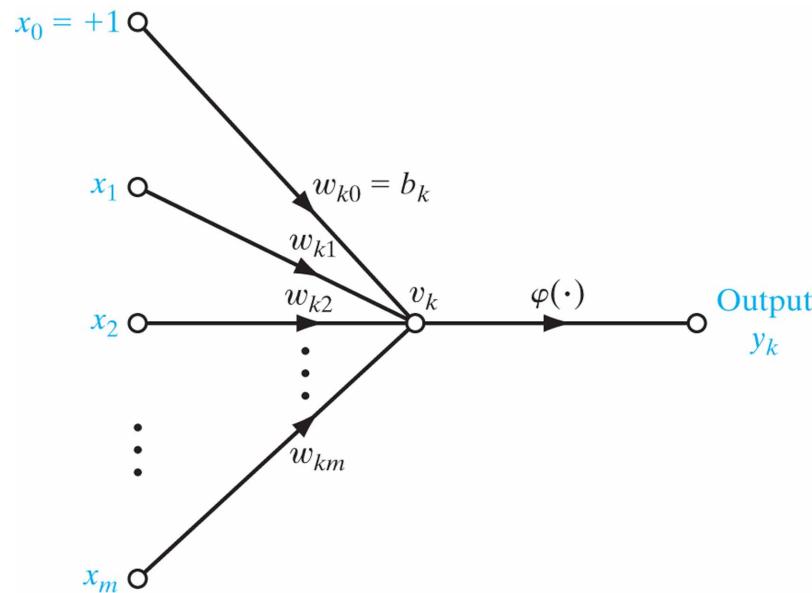
Funções de ativação

- Sigmoidal logística: $\varphi(v) = \frac{1}{1 + \exp(-av)}$



Representação

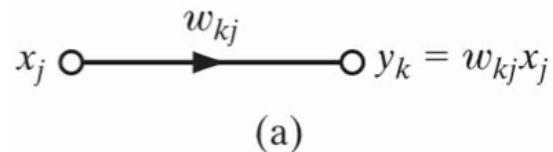
- Rede Neural é representada como um **grafo direto**
 - 3 regras básicas



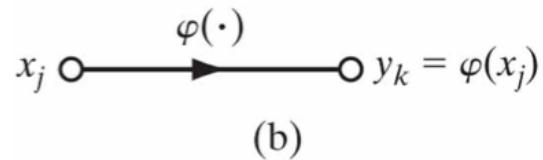
Representação

- **Regra 1:** o sinal flui em somente uma direção, representada pela seta que descreve a conexão

- (a) links sinápticos: relação linear entre a entrada e saída

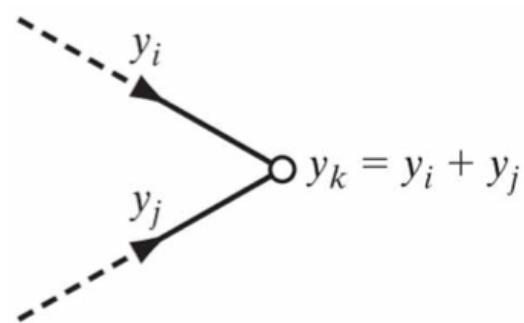


- (b) links de ativação: relação não linear entre a entrada e saída



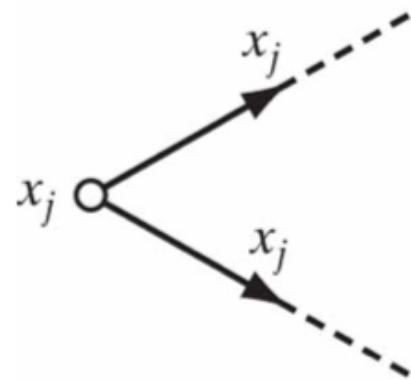
Representação

- **Regra 2:** um sinal em um nó é igual a soma algébrica de todos os sinais entrando no nó:



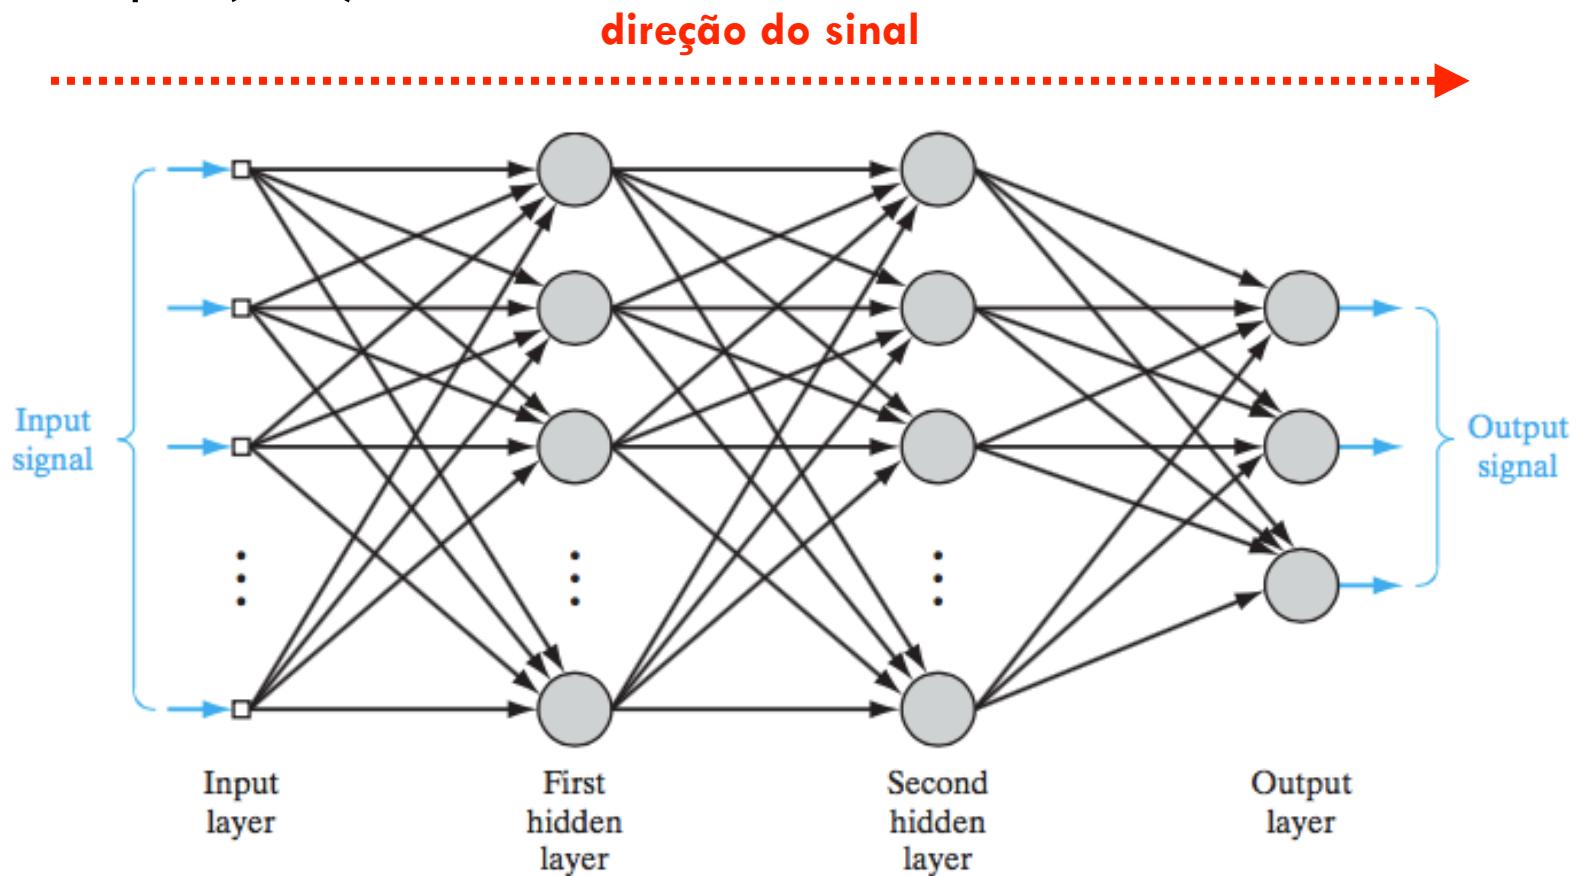
Representação

- **Regra 3:** o sinal em um nó é transmitido para todos os links de saída originários naquele nó



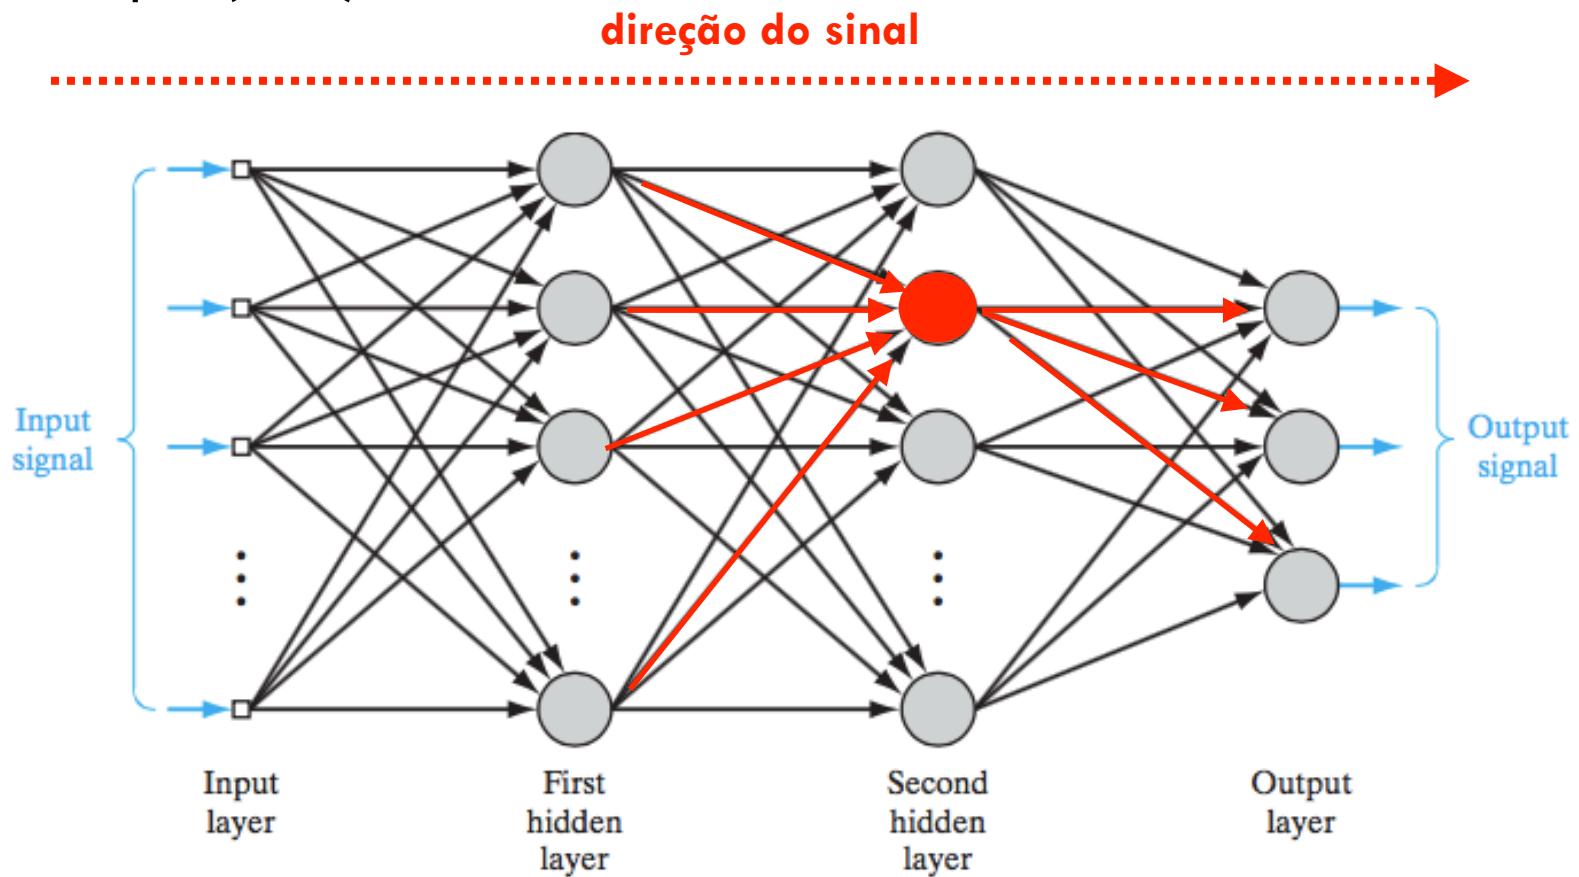
Representação

- Exemplo (MLP):



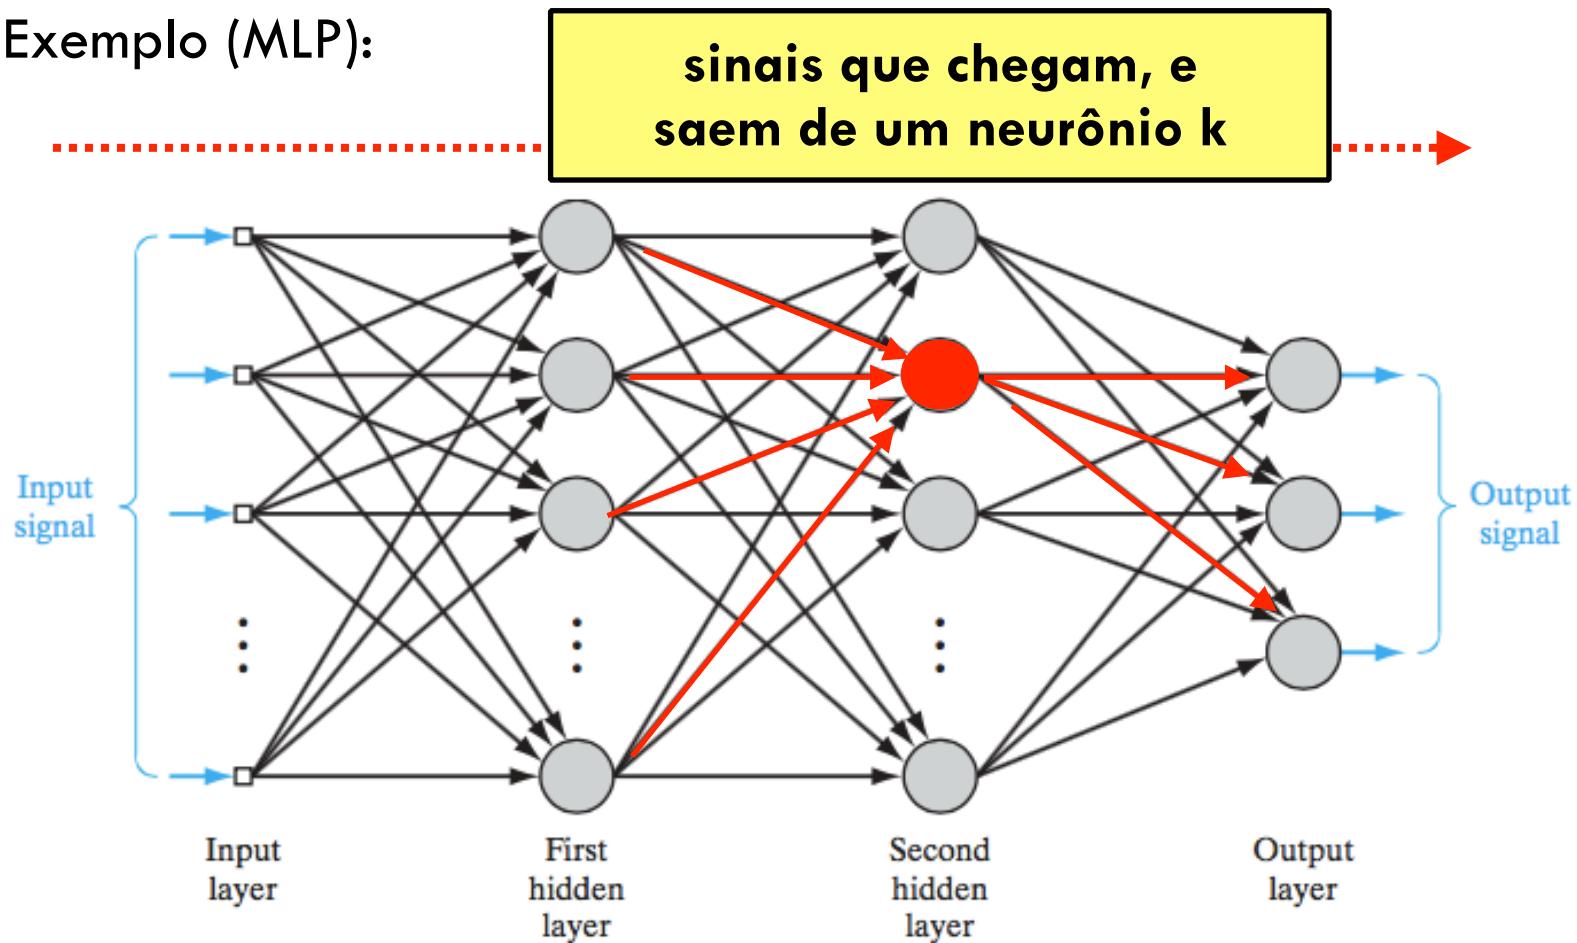
Representação

- Exemplo (MLP):



Representação

- Exemplo (MLP):

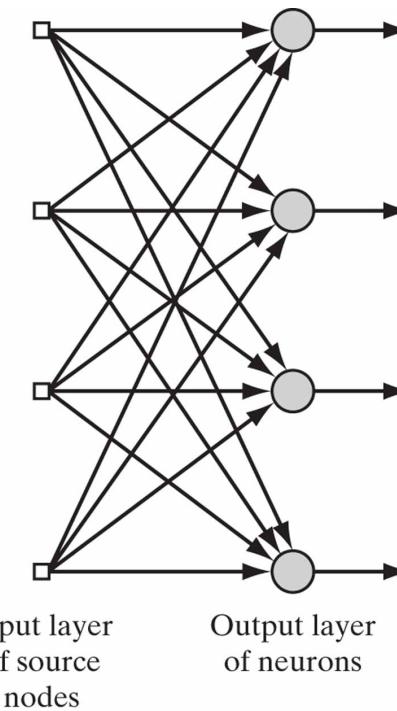


Arquiteturas

- A maneira como os neurônios são estruturados (arquitetura) tem relação direta em como a rede neural é treinada:
 - **A)** Redes Neurais de uma camada
 - **B)** Redes Neurais de múltiplas camadas
 - **C)** Redes Neurais recorrentes

Arquiteturas

- **A) Redes neurais de uma camada**
- Neurônios organizados em camadas:
 - entrada (dados)
 - saída

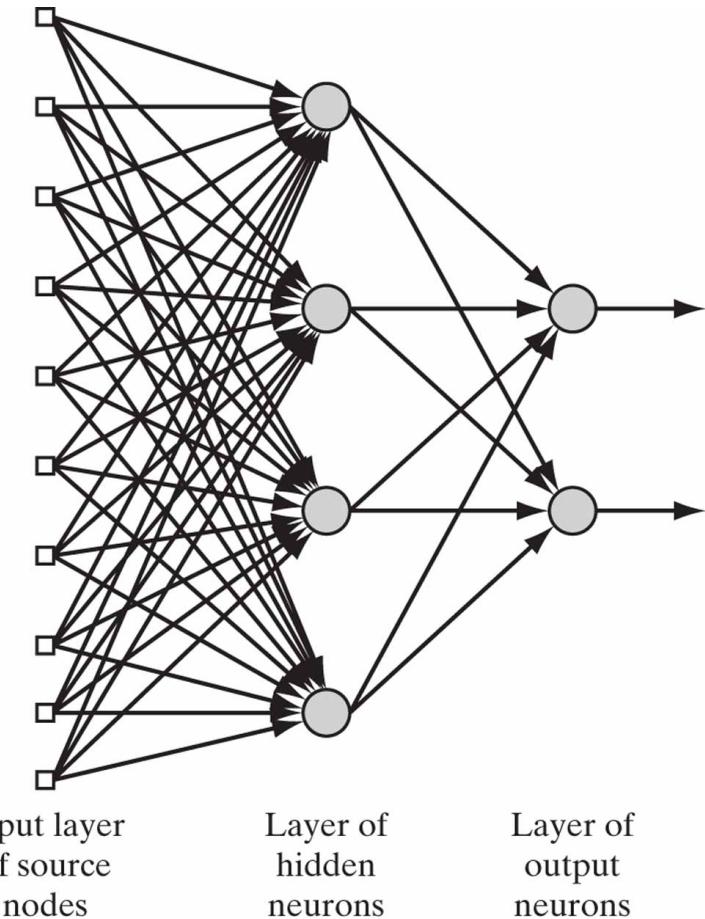


Arquiteturas

- **B) Redes neurais de múltiplas camadas**
- Camadas escondidas:
 - extratores de estatísticas de mais alta ordem
- Neurônios de uma camada têm como entradas sinais provenientes apenas dos neurônios das camadas anteriores

Arquiteturas

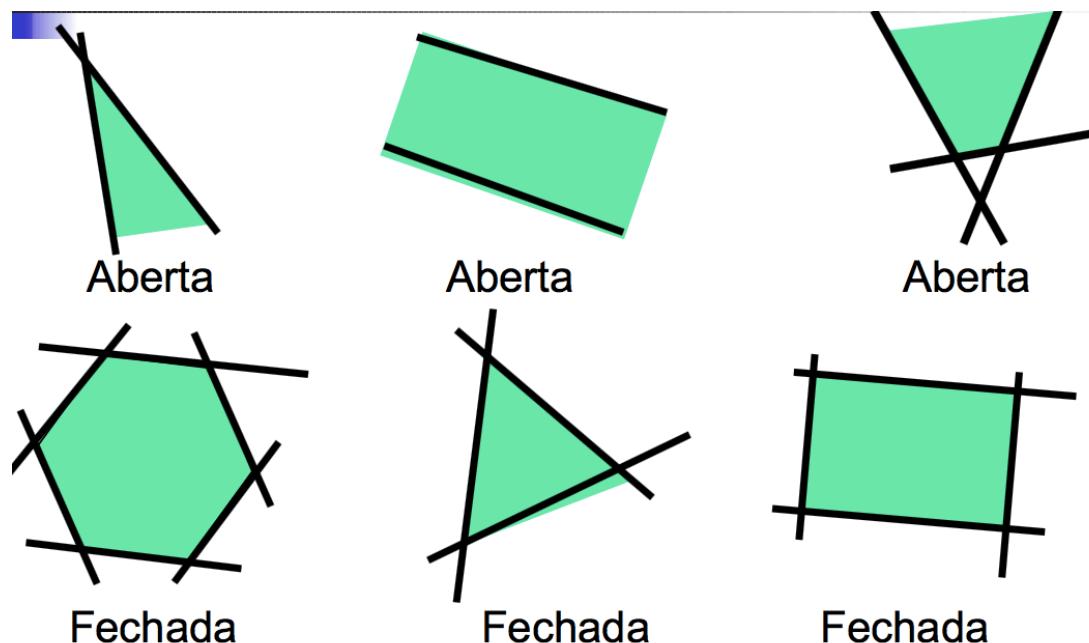
- **B) Redes neurais de múltiplas camadas**
- podem ser:
 - totalmente ou;
 - parcialmente conectadas



Arquiteturas

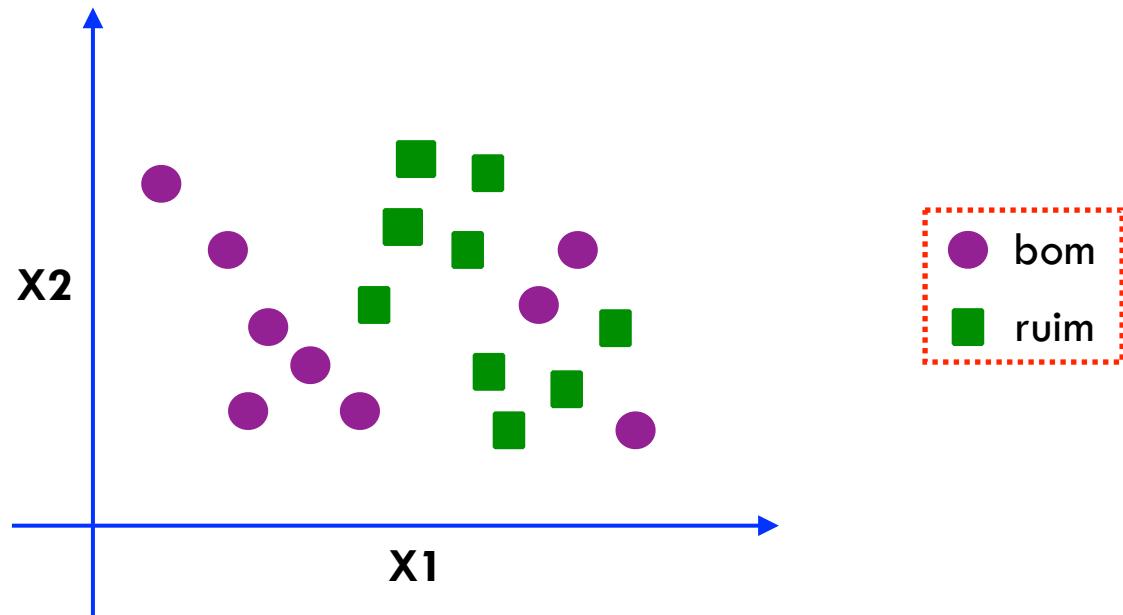
- Múltiplas camadas: combinações de hiperplanos

Cada **neurônio** cria um **hiperplano** separador, que combinados geram **superfícies convexas**



Arquiteturas

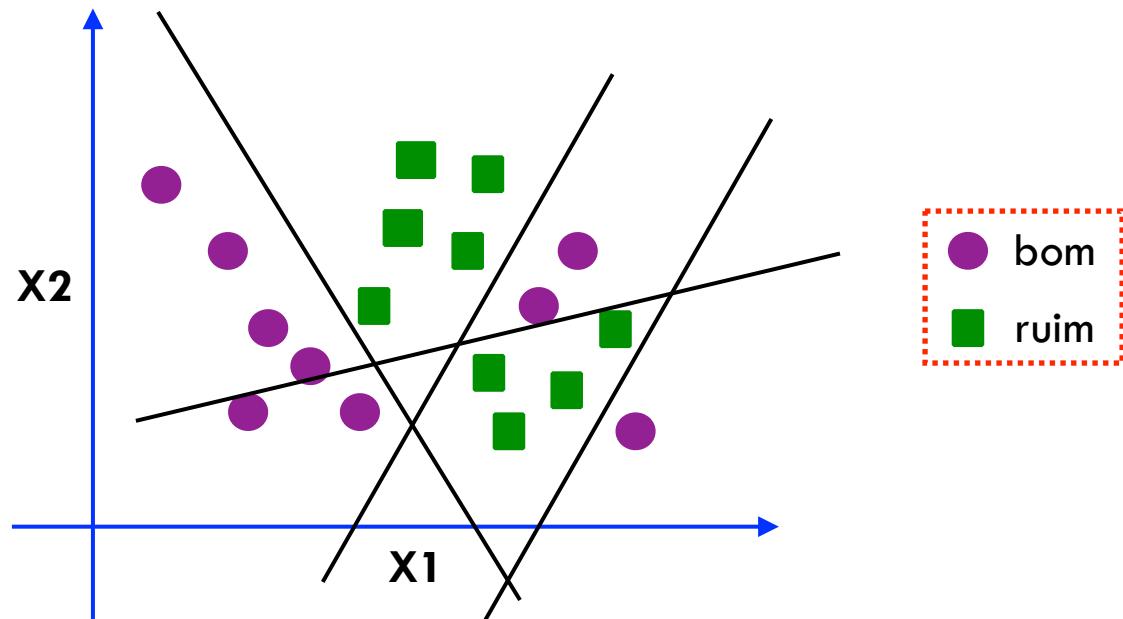
- Múltiplas camadas: combinações de hiperplanos



Tarefa preditiva
(**Classificação**/
Regressão)

Arquiteturas

- Múltiplas camadas: combinações de hiperplanos



Tarefa preditiva
(Classificação/
Regressão)

Arquiteturas

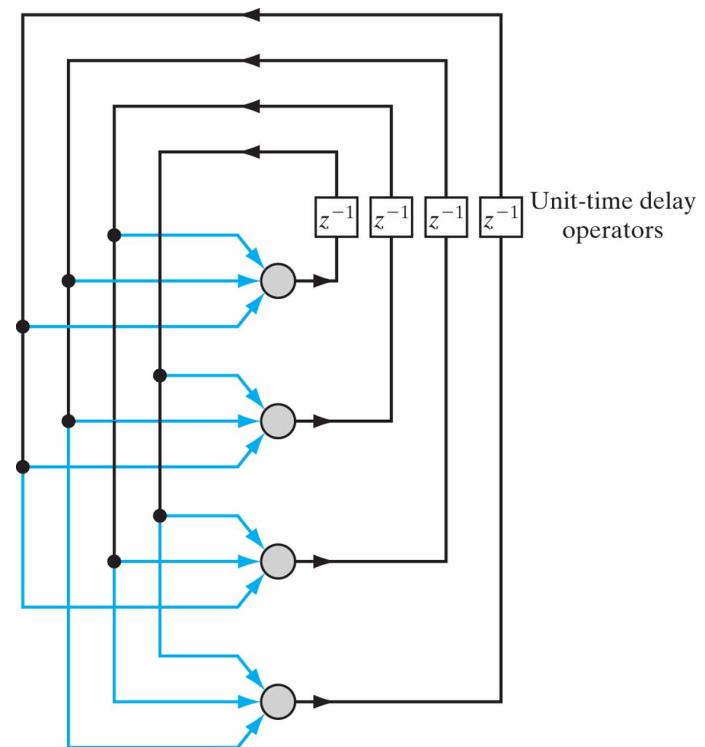
□ C) Redes Neurais Recorrentes

- Possuem retroalimentação
- Saídas dos neurônios podem servir de entrada para outros neurônios e também para o próprio neurônio corrente
- Podem ou não ter neurônios escondidos

Arquiteturas

□ C) Redes Neurais Recorrentes

- sem neurônios escondidos
- sem auto retroalimentação

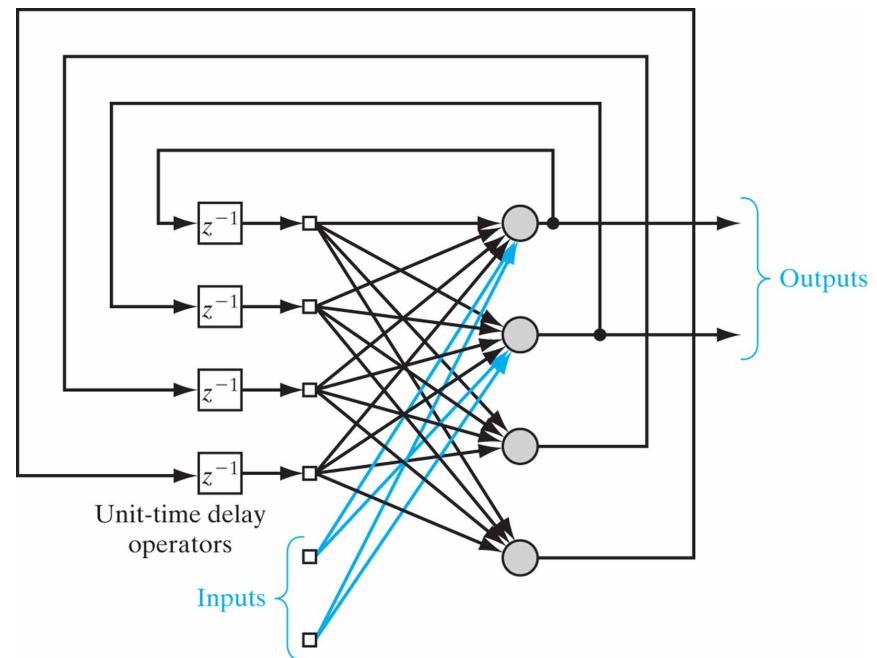


Arquiteturas

□ C) Redes Neurais Recorrentes

- com neurônios escondidos
- com auto retroalimentação

As saídas de uma iteração são as entradas da próxima iteração.
As saídas em t **realimentam** a rede no instante t+1



Aprendizado

- Além disso, a arquitetura da rede define qual é o tipo de algoritmo de aprendizado que será explorado.
 - **Aprendizado** é o processo de ajuste dos pesos sinápticos (W), de maneira que consigamos mapear as entradas (inputs) com as saídas esperadas (output)
- **Tipos de aprendizado**
 - Por correção de erro (regra delta)
 - Baseado em memória
 - Hebbiano
 - Competitivo

Aprendizado

- Além disso, a arquitetura da rede define qual é o tipo de algoritmo de aprendizado que será explorado.
 - Aprendizado** é o processo de ajuste dos pesos sinápticos (W) baseado na regra delta (Δ)

Os primeiros algoritmos que estudaremos explorarão a **regra delta** (correção do erro):

- Perceptron simples
- Perceptron Multicamadas (MLP - *Multilayer Perceptron*)

- Por correção de erro (regra delta)
- baseado em memória
- Hebbiano
- Competitivo

Exercícios

- 1 Descreva sucintamente o que você entende por Redes Neurais Artificiais (RNAs). Quais as principais vantagens e desvantagens deste modelo se comparado a outros modelos de Aprendizado de Máquina já estudados em outras disciplinas?
- 2 Quais as principais diferenças entre os tipos de rede: *feedforward* e *recorrentes*?
- 3 Em um neurônio McCulloch-Pitss, o que é o estado interno do neurônio? Como ele é calculado?

Exercícios

4

O que se entende por aprendizado em RNAs?

5

O que é a plasticidade do sistema nervoso central? Como este conceito é utilizado na área de RNAs?

Exercícios

6

Um neurônio recebe 4 entradas cujos valores são iguais a $X = \{10, -20, 4, -2\}$.

Os respectivos pesos sinápticos são $W = \{0.8, 0.2, -1, -0.9\}$.

Calcule a saída do neurônio para as seguintes situações:

- a ativação do neurônio é uma função linear ($f(x) = x$)
- b a ativação do neurônio é uma função degrau.

Obs: Assuma que o bias tenha peso nulo em ambos os casos, i.e., $w_0 = 0$.

Roteiro

- 1 Introdução**
- 2 Redes Neurais Artificiais**
- 3 Neurônio Artificial**
- 4 Modelagem de Redes Neurais**
- 5 Síntese / Próximas Aulas**
- 6 Referências**

Síntese/Revisão

- Paradigma Conexionista
- Redes Neurais Artificiais
- Inspiração Biológica (estrutura do cérebro)
- Neurônio artificial
- Funções de Ativação
- Topologias
- Algoritmos de Aprendizado

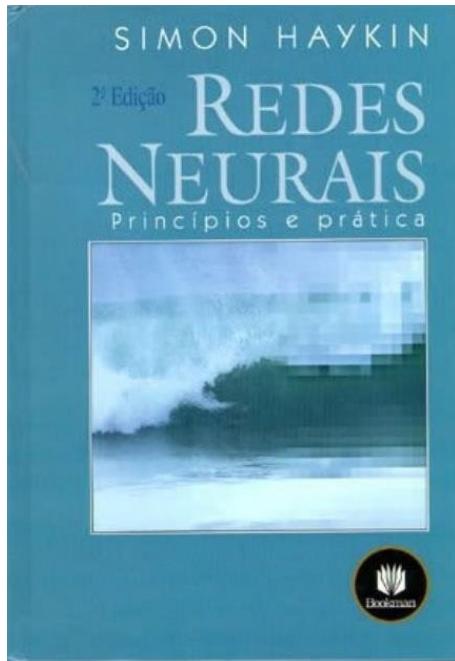
Próximas Aulas

- Perceptron Simples
 - regra Delta
- Perceptron Multi-camadas (MLPs)
 - Retropropagação (*Backpropagation*)

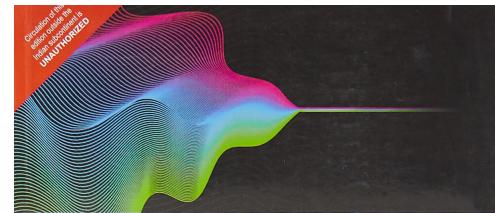
Roteiro

- 1 Introdução**
- 2 Redes Neurais Artificiais**
- 3 Neurônio Artificial**
- 4 Modelagem de Redes Neurais**
- 5 Síntese / Próximas Aulas**
- 6 Referências**

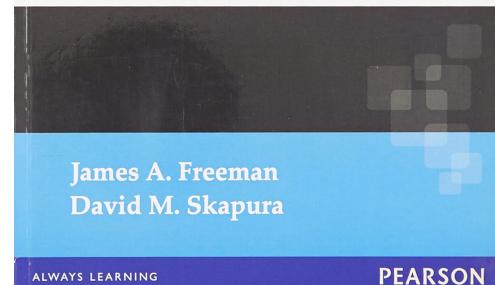
Literatura Sugerida



(Haykin, 1999)



Neural Networks
Algorithms, Applications and
Programming Techniques



(Freeman & Skapura, 1991)

Perguntas?

Prof. Rafael G. Mantovani

rafaelmantovani@utfpr.edu.br