

SICO70

SISTEMAS INTELIGENTES 2

Aula 05 - Backpropagation

Prof. Rafael G. Mantovani

Roteiro




- 1** Introdução
- 2** Backpropagation
- 3** Exemplo
- 4** Exercício
- 5** Referências

Roteiro

- 1** Introdução
- 2** Backpropagation
- 3** Exemplo
- 4** Exercício
- 5** Referências

Introdução

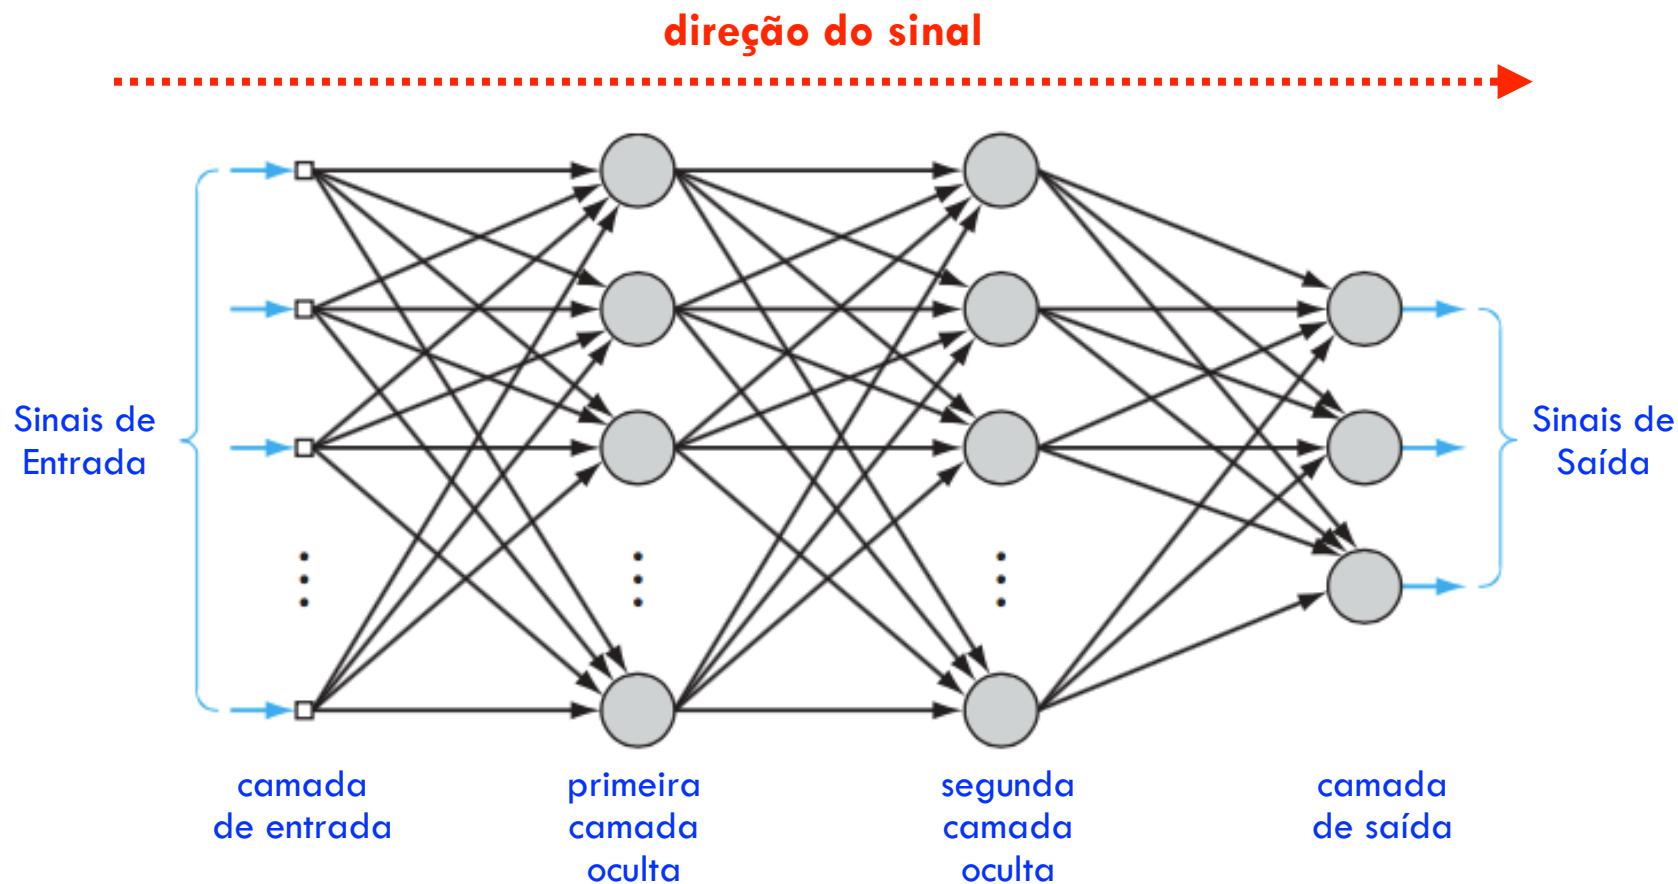


Introdução

- **Multilayer Perceptron:**

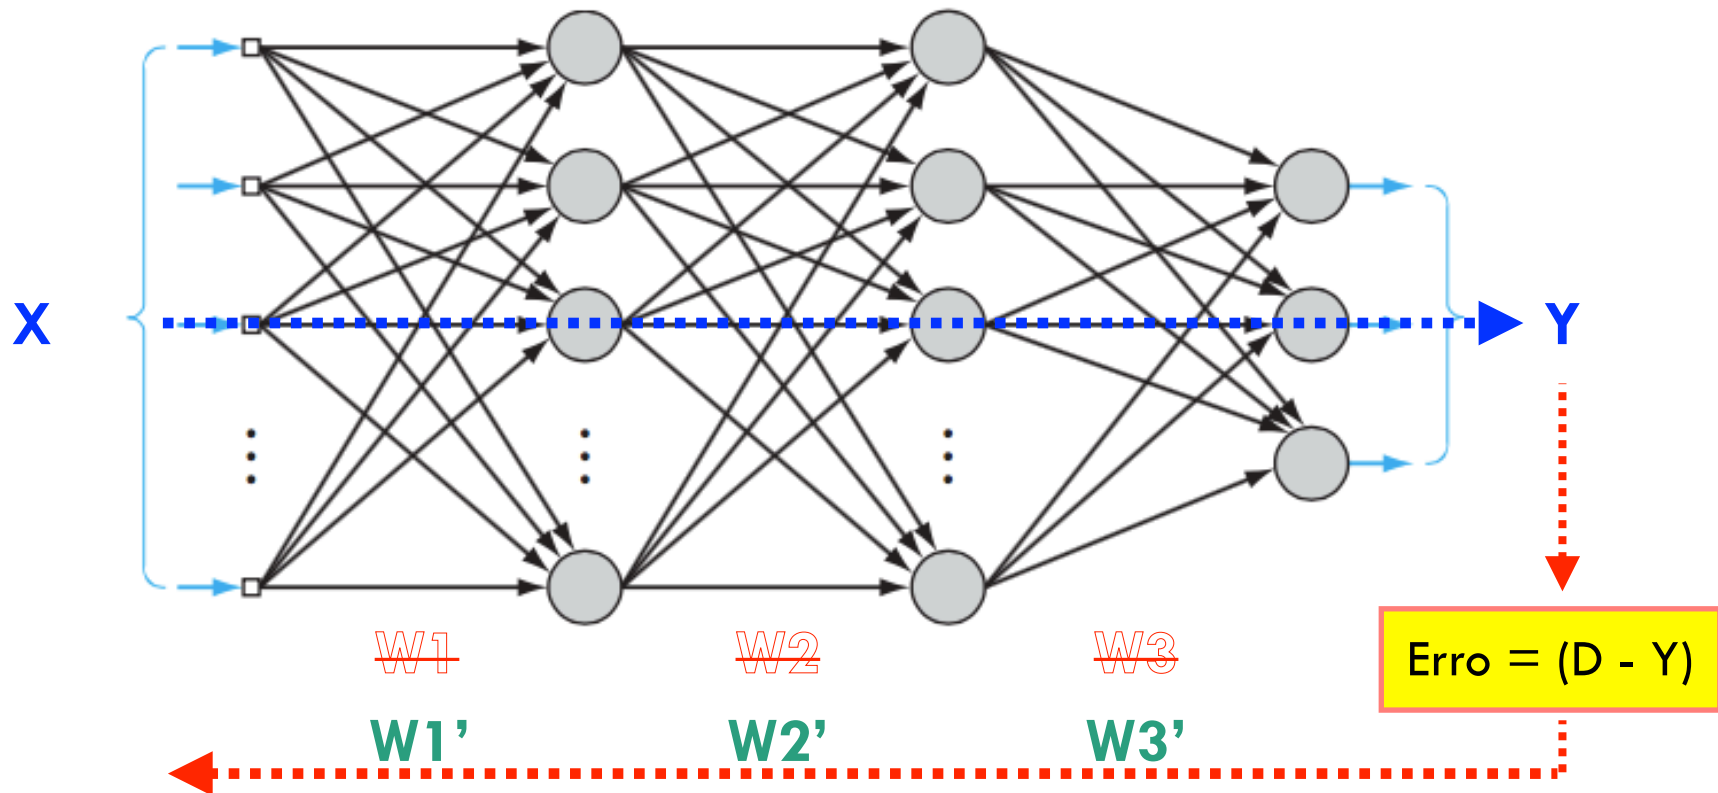
- neurônios possuem uma função de ativação **não-linear e diferenciável**
- contém uma ou mais camadas escondidas
- a rede possui alto grau de conectividade

Introdução



Introdução

- Backpropagation**



Introdução

- Se houverem **N** exemplos de treinamento, o erro médio sobre todos os exemplos (risco empírico) é dado por:

$$\varepsilon_{avg}(N) = \frac{1}{N} \sum_{n=1}^N \varepsilon(n) = \frac{1}{2N} \sum_{n=1}^N \sum_{j \in C} e_j^2(n)$$


Erro quadrático médio da época considera todos os neurônios da camada de saída **C** e todos os exemplos do conjunto de treinamento (**N**)

Roteiro




- 1 Introdução
- 2 Backpropagation
- 3 Exemplo
- 4 Exercício
- 5 Referências


Backpropagation




Backpropagation




Backpropagation



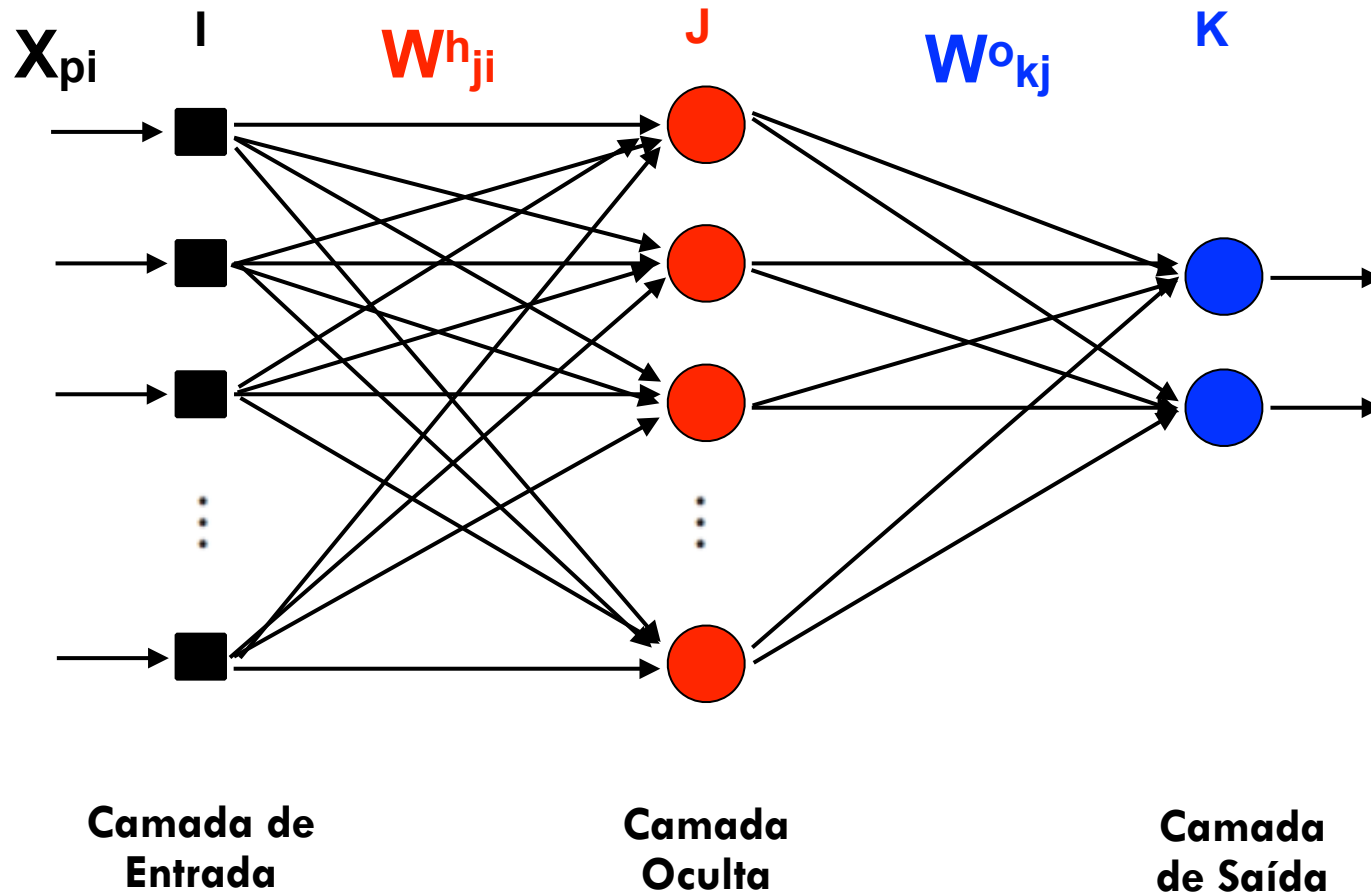
Backpropagation




Backpropagation



Backpropagation



Backpropagation




Os pesos sinápticos são matrizes:


W^h - conecta camada **oculta** e a camada de **entrada**

W^o - conecta a camada de **saída** e a camada **oculta**

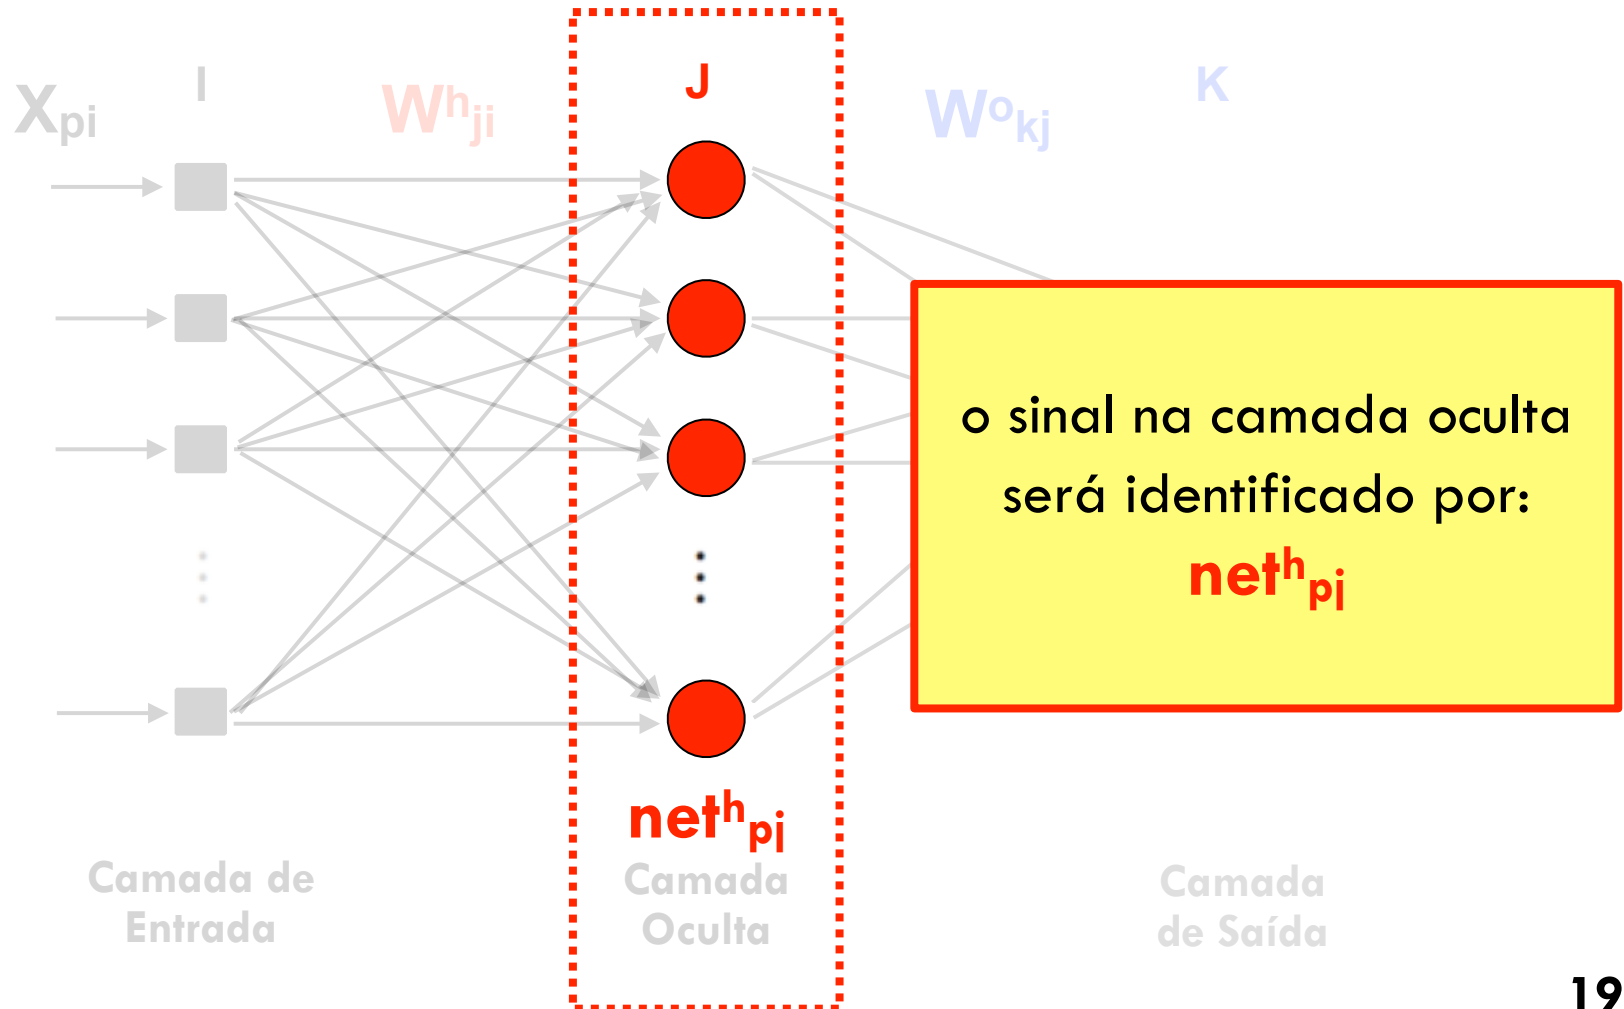
Backpropagation



Backpropagation



Backpropagation



Backpropagation

- 1 Sinal no neurônio de índice **J** na camada escondida:

$$net_{pj}^h = \sum_{i=1}^N W_{ji}^h x_{pi} + \theta_j^h$$

Backpropagation

- 1 Sinal no neurônio de índice **J** na camada escondida:

$$net_{pj}^h = \sum_{i=1}^N W_{ji}^h x_{pi} + \theta_j^h$$



N : número de neurônios na camada de entrada

Backpropagation

- 1 Sinal no neurônio de índice **J** na camada escondida:

$$net_{pj}^h = \sum_{i=1}^N W_{ji}^h x_{pi} + \theta_j^h$$

N : número de neurônios na camada de entrada

→ x_{pi} : exemplo de entrada fornecido para a rede

Backpropagation

- 1 Sinal no neurônio de índice **J** na camada escondida:

$$net_{pj}^h = \sum_{i=1}^N W_{ji}^h x_{pi} + \theta_j^h$$

N : número de neurônios na camada de entrada

x_{pi} : exemplo de entrada fornecido para a rede

→ W_{ji}^h : pesos sinápticos que conectam os valores de entrada i ao neurônio j

Backpropagation

- 1 Sinal no neurônio de índice **J** na camada escondida:

$$net_{pj}^h = \sum_{i=1}^N W_{ji}^h x_{pi} + \theta_j^h$$

N : número de neurônios na camada de entrada

x_{pi} : exemplo de entrada fornecido para a rede

W_{ji}^h : pesos sinápticos que conectam os valores de entrada i ao neurônio J

θ_j^h : bias do neurônio J

Backpropagation

- 1 Sinal no neurônio de índice **J** na camada escondida:

$$net_{pj}^h = \sum_{i=1}^N W_{ji}^h x_{pi} + \theta_j^h$$

Backpropagation


- 1 Sinal no neurônio de índice **J** na camada escondida:

$$net_{pj}^h = \sum_{i=1}^N W_{ji}^h x_{pi} + \theta_j^h$$

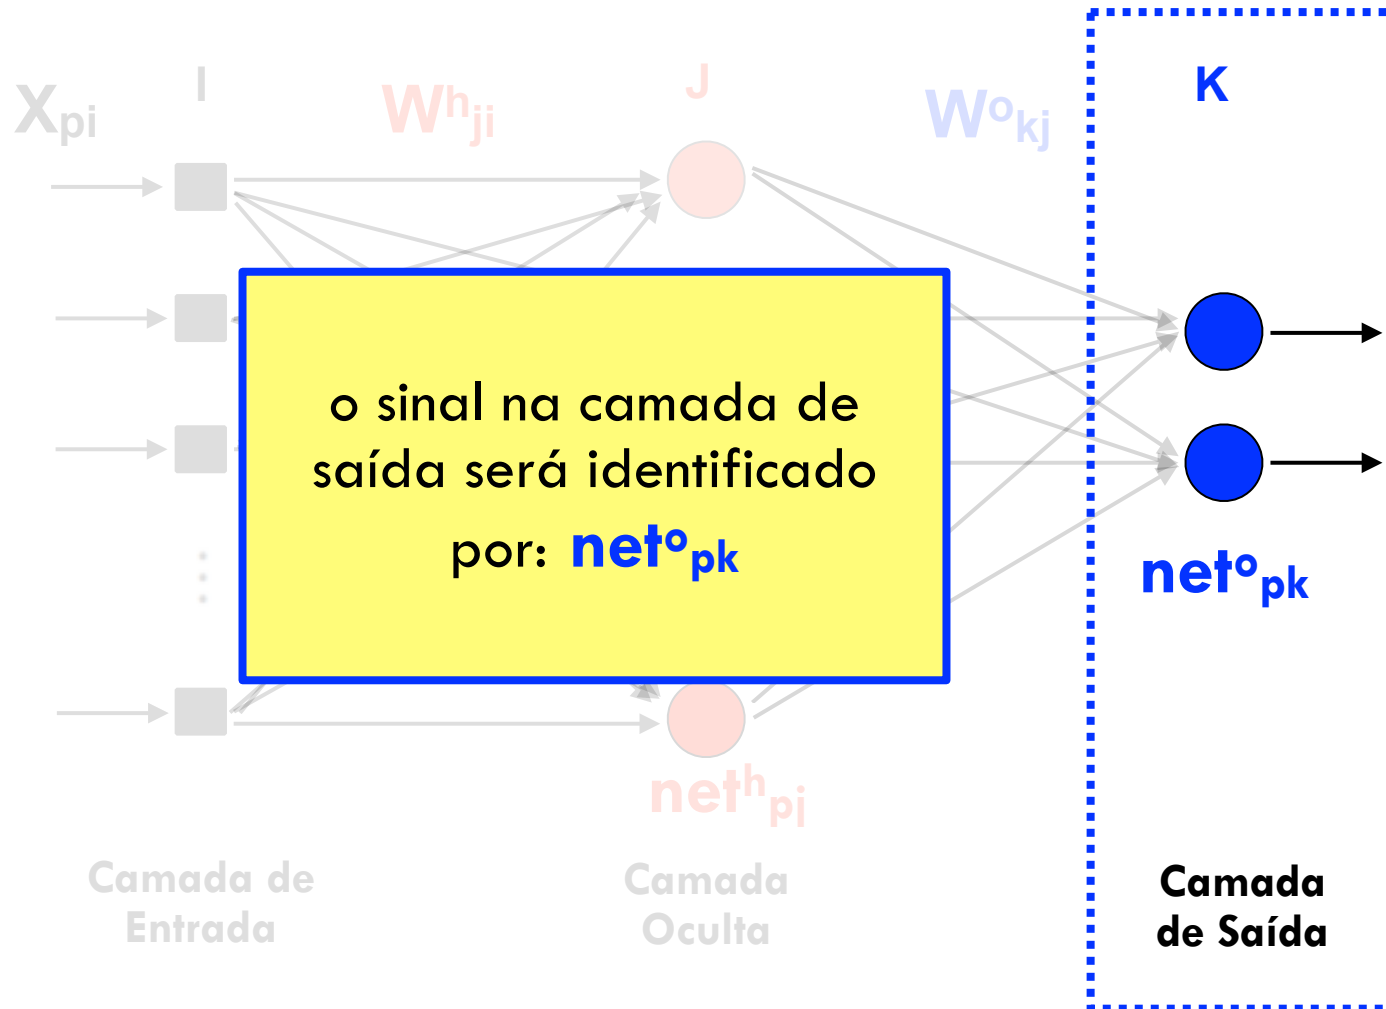
- 2 Ativação desse neurônio é igual a:

$$i_{pj} = f_j^h(net_{pj}^h)$$

Backpropagation



Backpropagation



Backpropagation

3 Sinal no neurônio de índice K na camada de saída:

Backpropagation

- 3 Sinal no neurônio de índice K na camada de saída:

$$net_{pk}^o = \sum_{j=1}^L W_{kj}^o i_{pj} + \theta_k^o$$

Backpropagation

- 3 Sinal no neurônio de índice k na camada de saída:

$$net_{pk}^o = \sum_{j=1}^L W_{kj}^o i_{pj} + \theta_k^o$$

L : número de neurônios na camada oculta

i_{pj} : valor da ativação do neurônio i na camada oculta

W_{kj}^o : pesos sinápticos que conectam o neurônio J com a camada escondida

θ_k^o : bias do neurônio k

Backpropagation

- 3 Sinal no neurônio de índice K na camada de saída:

$$net_{pk}^o = \sum_{j=1}^L W_{kj}^o i_{pj} + \theta_k^o$$

Backpropagation


- 3 Sinal no neurônio de índice k na camada de saída:

$$net_{pk}^o = \sum_{j=1}^L W_{kj}^o i_{pj} + \theta_k^o$$


- 4 Saída desse neurônio é igual a:

$$o_{pk} = f_k^o(net_{pk}^o)$$


Backpropagation



Backpropagation



Backpropagation



Backpropagation

- 5 Calcular os termos de erro para as unidades de saída:

$$\delta^o_{pk} = (y_{pk} - o_{pk}) * f'_{o_k}(\text{net}^o_{pk})$$

Backpropagation

- 5 Calcular os termos de erro para as unidades de saída:

$$\delta_{pk} = (y_{pk} - o_{pk}) * f'_{o_k}(\text{net}_{pk})$$

 y_{pk} : saída esperada no neurônio k

Backpropagation

- 5 Calcular os termos de erro para as unidades de saída:

$$\delta_{pk} = (y_{pk} - o_{pk}) * f'_{o_k}(\text{net}_{pk})$$

y_{pk} : saída esperada no neurônio k

→ o_{pk} : saída obtida no neurônio k

Backpropagation

- 5 Calcular os termos de erro para as unidades de saída:

$$\delta^o_{pk} = (y_{pk} - o_{pk}) * f'_{o'_k} (net^o_{pk})$$

y_{pk} : saída esperada no neurônio k

o_{pk} : saída obtida no neurônio k

▶ net^o_{pk} : sinal obtido no neurônio k

Backpropagation

- 5 Calcular os termos de erro para as unidades de saída:

$$\delta_{pk}^o = (y_{pk} - o_{pk}) * f_{k'}^o (net_{pk}^o)$$


y_{pk} : saída esperada no neurônio k

o_{pk} : saída obtida no neurônio k


net_{pk}^o : sinal obtido no neurônio k

→ f_k^o : derivada da função de ativação do neurônio k

Backpropagation



Backpropagation



Backpropagation

- 6 Calcular os termos de erro para as unidades ocultas:

$$\delta^h_{pj} = f'^h_j(\text{net}^h_{pj}) \sum_k (\delta^o_{pk} * W^o_{kj})$$

Backpropagation

- 6 Calcular os termos de erro para as unidades ocultas:

$$\delta_{pj}^h = f_j^{\prime h}(\text{net}_{pj}^h) \sum_k (\delta_{pk}^o * W_{kj}^o)$$

δ_{pk}^o

W_{kj}^o

net_{pj}^h

$f_j^{\prime h}$

Backpropagation

- 6 Calcular os termos de erro para as unidades ocultas:

$$\delta_{pj}^h = f_j^h(\text{net}_{pj}^h) \sum_k (\delta_{pk}^o * W_{kj}^o)$$

δ_{pk}^o : termo de erro (gradiente) para o neurônio k da camada de saída

W_{kj}^o : pesos sinápticos que conectam o neurônio j da camada oculta a todos os neurônios k da camada de saída

net_{pj}^h : sinal obtido no neurônio j

f_j^h : derivada da função de ativação do neurônio j


Backpropagation

- 6 Calcular os termos de erro para as unidades ocultas:

$$\delta^h_{pj} = f'^h_j(\text{net}^h_{pj}) \sum_k (\delta^o_{pk} * W^o_{kj})$$

Obs: o erro das unidades ocultas é calculado **ANTES** do ajuste de pesos da camada de saída

Backpropagation



Backpropagation


- 7 Atualizar os pesos da camada de saída

$$W^{o}_{kj} (t+1) = W^{o}_{kj} (t) + \eta * \delta^{o}_{pk} * i_{pj}$$

- 8 Atualizar os pesos da camada oculta

$$W^{h}_{ji} (t+1) = W^{h}_{ji} (t) + \eta * \delta^{h}_{pj} * x_{pi}$$

Backpropagation



Backpropagation

- 9 Calcular o erro total da **época**
 - Indica o quão bem a rede está aprendendo.
 - quando for menor que um limiar (***threshold***), parar

Algoritmo resumido

Multilayer Perceptron (MLP):

Início algoritmo

1. Aplicar um **vetor de entrada** para a rede (**X**) e calcular os valores de saída
2. Comparar as **saídas atuais** com as **saídas desejadas** e obter uma medida de **erro**
3. Determinar em qual **direção** (+ ou -) se deve modificar os pesos para minimizar o erro
4. Determinar a **quantidade** para se modificar cada peso
5. Aplicar as **correções aos pesos**
6. Repetir de 1 a 5 com todos os exemplos de treinamento, até que uma margem de erro de treinamento seja atingida


Fim algoritmo

Roteiro



- 1 Introdução
- 2 Backpropagation
- 3 Exemplo
- 4 Exercício
- 5 Referências

Exemplo



XOR dataset

A	B	Y
0	0	0
0	1	1
1	0	1
1	1	0

Exemplo

época	θ_{h0}	θ_{h1}	θ_{o0}	W^{h00}	W^{h10}	W^{h01}	W^{h11}	W^{o00}	W^{o01}
0	0.05	0.06	0.07	0.2	0.15	0.35	0.18	0.10	0.12
1									
2									

- $\eta = 0.2$
- $f(\text{net}) = 1 / (1 + \exp^{-\text{net}})$
- $f'(\text{net}) = \text{net} (1 - \text{net})$

Roteiro


- 1 Introdução
- 2 Backpropagation
- 3 Exemplo
- 4 Exercício
- 5 Referências

Exercício

época	θ_{h0}	θ_{h1}	θ_{o0}	W^{h00}	W^{h10}	W^{h01}	W^{h11}	W^{o00}	W^{o01}
0	0.05	0.06	0.07	0.2	0.15	0.35	0.18	0.10	0.12
1									
2									

- $X = \text{XOR dataset}$
- $\eta = 0.2$
- $f(\text{net}) = \text{net}^3 + 0.5$
- $f'(\text{net}) = 3 * \text{net}^2$


Exercício




Roteiro

- 1 Introdução
- 2 Backpropagation
- 3 Exemplo
- 4 Exercício
- 5 Referências

Literatura Sugerida




(Haykin, 1999)




(Freeman & Skapura, 1991)

Literatura Sugerida



[Faceli et al, 2011]



[Braga et al, 2007]



Perguntas?

Prof. Rafael G. Mantovani

rgmantovani@gmail.com